



图书分类号： (黑体五号, 见图书馆首页)

学校代码： 10615 (黑体五号)

西南石油大学

# 专业学位硕士学位论文

## (全日制)

论 文 题 目 基于无监督学习的异  
常网络流量检测研究  
与实现

学 位 类 别 工程硕士

专业学位领域 网络与信息安全

研 究 方 向 异常检测

研 究 生 姓 名 王羲

学 号 202322000619

校 内 导 师 姓 名 钟学燕

校 外 导 师 姓 名

论文完成时间：2026年月

**西南石油大学研究生学位论文知识产权声明书及  
学位论文版权使用授权书**

本人完全了解学校有关保护知识产权的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属于西南石油大学。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版。本人允许论文被查阅和借阅。学校可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时，本人保证，毕业后结合学位论文研究课题再撰写的文章一律注明作者单位为西南石油大学。

本学位论文属于

1、保密（     ），在     年解密后适用本授权书。

2、不保密（     ）

(请在以上相应括号内打“√”)

学位论文作者签名：\_\_\_\_\_ 指导教师签名：\_\_\_\_\_  
年    月    日                      年    月    日

**西南石油大学研究生学位论文独创性声明**

本人声明：所呈交的研究生学位论文是本人在导师指导下进行的研究工作及取得的成果。据我所知，除了文中特别加以标注和致谢的地方外，本论文不包含其他人已经发表或撰写过的研究成果，也不包含其他人为获得西南石油大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：  
年    月    日

## 摘 要

随着常规天然气资源的逐渐枯竭，全球能源开发的重心正逐步转向非常规储层，尤其是页岩气。中国在四川盆地、鄂尔多斯盆地和塔里木盆地等地拥有极为丰富的页岩气资源，这些资源为国家能源储备提供了重要支撑。然而，页岩气的开采面临着诸多技术挑战，其中井筒积液问题尤为突出。页岩气储层的地质特征复杂，孔隙小、裂缝少且渗透率低，导致气体释放缓慢。当气体携液能力不足以带出液体时，液体就会在井筒内积聚，最终形成积液。如何有效解决井筒积液问题，已成为页岩气开采中亟待突破的关键技术难题。目前，数据驱动方法在井筒积液检测领域展现出巨大潜力，但实际应用中仍面临诸多挑战。有监督学习难以获取足够标签数据，无监督学习难以设定异常阈值且容易误归类，而国内页岩气藏的非均质性进一步限制了数据驱动模型的检测效果。此外，数据驱动模型在生产环境中还面临数据泄露和恶意攻击等安全风险，现有防御措施仍不够健壮。为有效应对页岩气井筒积液检测中的复杂挑战，本研究开发了一套系统化的创新技术框架。

首先，针对现有学习策略的局限性，提出了一种基于半监督学习的二阶段积液检测模型，旨在实现积液的高效检测与严重程度分级。在第一阶段，采用基于长短期记忆网络的自编码器和动态阈值算法来识别积液数据。在第二阶段，构建了一种组合神经网络，包括双注意力增强模块、多随机卷积核变换网络和多层感知机，用于对积液的严重程度进行精确分级。其中，双注意力增强模块通过块间和块内注意力机制，能够自适应地提取关键特征，显著提升特征表达能力。多随机卷积核变换网络则利用随机卷积核对特征图进行处理，进一步提取特征值，为最终的严重程度分级提供有力支持。此外，为了充分利用有限的标签数据，引入了半监督学习策略，通过伪标签生成和迭代训练，显著提升了模型在少量标签数据情况下的性能。在三个独立数据集上，模型的平均 F1 得分分别达到了 0.82、0.83 和 0.86。

其次，针对页岩气藏的非均质性问题，本研究提出了一种基于联邦学习的页岩气井筒积液检测模型协同优化方案。由于页岩气藏不同区块的地质条件和施工工艺存在显著差异，这使得基于单一全局模型的联邦学方案难以适应所有局部数据特征。为此，我们设计了一种局部化中心模型方案。该方案基于本研究所提出动态双向权重调节机制，确保每个参与方能够根据本地数据特征训练出贴合的模型。动态双向权重调节机制包含中心化加权聚合算法和知识迁移权重调节算法。前者根据各参与方的模型质量来动态调整其在局部化中心模型中的权重，后者根据各参与方模型的贡献率来调节知识迁移过程中的知识比例。此外，我们还通过微调进一步优化了局部化中心模型性能，使其更好地适应本地数据分布。在三个数据集上，经过协同优化后的模型平均 F1 得分分别提高了 0.04、0.03 和 0.01。

最后，在数据驱动模型的安全性方面，本研究提出了一种综合性的隐私保护与攻击

防御方案。本研究将生成对抗网络与差分隐私相结合，通过设计鉴别器损失和噪声尺度正则化损失两个损失函数，实现了隐私保护与模型性能之间的平衡。实验结果表明，与仅使用差分隐私相比，在隐私保护强度几乎不变的情况下，模型平均 F1 得分提升了约 0.03；针对投毒攻击，我们提出了基于注意力蒸馏的知识迁移算法和中心化弹性聚合算法，显著增强了模型在复杂攻击环境下的鲁棒性。在只用 5% 干净数据微调下，5 种数据投毒攻击的成功率均低于 10%，而模型投毒攻击导致的平均 F1 得分下降幅度控制在 0.05 以内。

**关键词：**井筒积液；数据驱动；联邦学习；隐私保护；投毒攻击防御

## Abstract

With the gradual depletion of conventional natural gas resources, the focus of global energy development is gradually shifting towards unconventional reservoirs, especially shale gas. China has extremely rich shale gas resources in Sichuan Basin, Ordos Basin and Tarim Basin, which provide important support for national energy reserves. However, the extraction of shale gas faces many technical challenges, among which the problem of liquid loading is particularly prominent. The geological characteristics of shale gas reservoirs are complex, with small pores, few fractures, and low permeability, resulting in slow gas release. When the gas carrying capacity is insufficient to remove the liquid, the liquid will accumulate in the wellbore, eventually forming a liquid loading. How to effectively solve the problem of liquid loading has become a key technical challenge that urgently needs to be overcome in shale gas extraction. At present, data-driven methods have shown great potential in the field of liquid loading detection, but there are still many challenges in practical applications. Supervised learning is difficult to obtain sufficient labeled data, unsupervised learning is difficult to set anomaly thresholds and prone to misclassification, while the heterogeneity of shale gas reservoirs in China further limits the detection performance of data-driven models. In addition, data-driven models also face security risks such as data breaches and malicious attacks in production environments, and existing defense measures are still not robust enough. To effectively address the complex challenges in shale gas liquid loading detection, this study has developed a systematic and innovative technology framework.

Firstly, a two-stage liquid loading detection model based on semi supervised learning is proposed to address the limitations of existing learning strategies, aiming to achieve efficient detection and severity grading of effusion. In the first stage, autoencoders based on long short-term memory networks and dynamic thresholding algorithms are used to identify liquid loading data. In the second stage, a composite neural network was constructed, including a dual attention enhancement module, a multi random convolutional kernel transformation network, and a multi-layer perceptron, for accurately grading the severity of liquid loading. Among them, the dual attention enhancement module can adaptively extract key features and significantly improve feature expression ability through inter block and intra block attention mechanisms. The multi random convolution kernel transformation network utilizes random convolution kernels to process feature maps and further extract feature values, providing strong support for the final severity grading. In addition, in order to fully utilize limited labeled data, a semi supervised learning strategy was introduced, which significantly improved the performance of the model in the case of a small amount of labeled data through pseudo label generation and iterative train-

ing. On three independent datasets, the average F1 scores of the model reached 0.82, 0.83, and 0.86, respectively.

Secondly, in response to the heterogeneity of shale gas reservoirs, this study proposes a collaborative optimization scheme for shale gas well liquid loading detection model based on federated learning. Due to significant differences in geological conditions and construction techniques among different blocks of shale gas reservoirs, federated learning schemes based on a single global model are difficult to adapt to all local data features. For this purpose, we have designed a localized center model scheme. This scheme is based on the dynamic bidirectional weight adjustment mechanism proposed by our research institute, ensuring that each participant can train a suitable model based on local data features. The dynamic bidirectional weight adjustment mechanism includes centralized weighted aggregation algorithm and knowledge transfer weight adjustment algorithm. The former dynamically adjusts its weight in the localized center model based on the model quality of each participant, while the latter adjusts the knowledge proportion in the knowledge transfer process based on the contribution rate of each participant's model. In addition, we further optimized the performance of the localized center model by fine-tuning it to better adapt to the local data distribution. On three datasets, the average F1 score of the model after collaborative optimization increased by 0.04, 0.03, and 0.01, respectively.

Finally, in terms of the security of data-driven models, this study proposes a comprehensive privacy protection and attack defense scheme. This study combines generative adversarial networks with differential privacy, and achieves a balance between privacy protection and model performance by designing two loss functions: discriminator loss and noise scale regularization loss. The experimental results show that compared with using only differential privacy, the average F1 score of the model increased by about 0.03 while the privacy protection strength remained almost unchanged; We propose a knowledge transfer algorithm based on attention distillation and a centralized elastic aggregation algorithm for poisoning attacks, which significantly enhance the robustness of the model in complex attack environments. Under the fine-tuning of only 5% clean data, the success rates of all 5 data poisoning attacks were below 10%, while the average F1 score decrease caused by model poisoning attacks was controlled within 0.05.

**Key words:** Liquid loading; Data-driven; Federated learning; Privacy protection; Poisoning attack defense

# 目 录

|                         |    |
|-------------------------|----|
| 第 1 章 绪论                | 1  |
| 1.1 研究背景与意义             | 1  |
| 1.2 国内外研究现状             | 3  |
| 1.2.1 异常流量检测研究现状        | 3  |
| 1.2.2 基于异常流量检测的机器学习方法   | 5  |
| 1.2.3 基于异常流量检测的深度学习的方法  | 6  |
| 1.3 本文主要研究内容及创新         | 7  |
| 1.3.1 主要研究内容            | 7  |
| 1.3.2 主要创新              | 9  |
| 1.4 本文组织架构              | 9  |
| 第 2 章 相关技术及理论介绍         | 11 |
| 2.1 异常流量数据检测相关概念        | 11 |
| 2.1.1 数据包与 PCAP 接口      | 11 |
| 2.1.2 网络流量数据            | 12 |
| 2.1.3 SSL/TLS 加密协议原理与发展 | 13 |
| 2.1.4 网络攻击类型            | 15 |
| 2.2 相关算法                | 15 |
| 2.2.1 有监督学习             | 16 |
| 2.2.2 无监督学习             | 16 |
| 2.2.3 半监督学习             | 16 |
| 2.2.4 自监督学习             | 17 |
| 2.3 深度学习相关理论            | 17 |
| 2.3.1 人工神经网络结构          | 18 |
| 2.3.2 注意力机制             | 20 |
| 2.3.3 损失函数              | 21 |
| 2.3.4 注意力机制             | 22 |
| 2.4 系统开发设计基础            | 22 |
| 2.4.1 FastAPI 框架        | 22 |
| 2.4.2 Kafka             | 22 |
| 2.4.3 ElasticSearch     | 23 |
| 2.4.4 Zeek              | 23 |
| 2.5 本章小结                | 23 |

|       |                              |    |
|-------|------------------------------|----|
| 第 3 章 | 基于实例多样性加权的无监督超球体学习方法 .....   | 24 |
| 3.1   | 引言 .....                     | 24 |
| 3.2   | 长尾分布问题分析与实例多样性度量 .....       | 24 |
| 3.2.1 | 无监督异常检测中的长尾分布特性 .....        | 24 |
| 3.2.2 | 基于 IED 的实例多样性度量定义 .....      | 25 |
| 3.3   | 基于 IED 加权的超球体模型构建与算法实现 ..... | 26 |
| 3.3.1 | 模型整体框架设计 .....               | 26 |
| 3.3.2 | 多样性感知权重生成机制 .....            | 27 |
| 3.3.3 | 优化目标函数构建 .....               | 27 |
| 3.4   | 数据预处理 .....                  | 28 |
| 3.4.1 | 数据清洗 .....                   | 29 |
| 3.4.2 | 异常值处理 .....                  | 30 |
| 3.4.3 | 缺失值处理 .....                  | 31 |
| 3.4.4 | 特征筛选 .....                   | 31 |
| 3.4.5 | 特征降维 .....                   | 32 |
| 3.5   | 实验结果与分析 .....                | 32 |
| 3.5.1 | 评价指标 .....                   | 33 |
| 3.5.2 | 对比实验 .....                   | 34 |
| 3.5.3 | 消融实验 .....                   | 35 |
| 3.6   | 本章小结 .....                   | 37 |
| 第 4 章 | 面向未知攻击的多模式无监督异常流量检测方法 .....  | 39 |
| 4.1   | 引言 .....                     | 39 |
| 4.2   | 模型设计 .....                   | 39 |
| 4.2.1 | 多模式无监督聚类建模思想 .....           | 39 |
| 4.2.2 | 多模式无监督聚类建模方法 .....           | 41 |
| 4.2.3 | 异常得分计算机制和损失函数 .....          | 43 |
| 4.3   | 实验数据集与环境 .....               | 44 |
| 4.3.1 | 实验数据集介绍 .....                | 44 |
| 4.3.2 | 实验环境与参数设置 .....              | 45 |
| 4.4   | 实验与分析 .....                  | 47 |
| 4.4.1 | 评价指标 .....                   | 47 |
| 4.4.2 | 实验结果 .....                   | 47 |
| 4.4.3 | 对比实验 .....                   | 47 |
| 4.4.4 | 消融实验 .....                   | 47 |
| 4.5   | 本章小结 .....                   | 47 |
| 第 5 章 | 针对投毒攻击的页岩气井积液检测联邦防御算法 .....  | 48 |

|                    |                      |    |
|--------------------|----------------------|----|
| 5.1                | 隐私保护 .....           | 48 |
| 5.1.1              | 差分隐私 .....           | 48 |
| 5.1.2              | 生成对抗网络 .....         | 50 |
| 5.2                | 数据投毒攻击防御 .....       | 51 |
| 5.2.1              | 基于注意力蒸馏的防御算法 .....   | 51 |
| 5.2.2              | 基于注意力蒸馏的知识迁移算法 ..... | 52 |
| 5.3                | 模型投毒攻击防御 .....       | 53 |
| 5.3.1              | 拜占庭弹性聚合算法 .....      | 53 |
| 5.3.2              | 中心化弹性聚合算法 .....      | 54 |
| 5.4                | 实验与分析 .....          | 55 |
| 5.4.1              | 隐私保护实验与分析 .....      | 55 |
| 5.4.2              | 数据投毒攻击防御实验与分析 .....  | 60 |
| 5.4.3              | 模型投毒攻击防御实验与分析 .....  | 61 |
| 5.5                | 本章小结 .....           | 64 |
| 第 6 章              | 总结与展望 .....          | 65 |
| 6.1                | 本文工作总结 .....         | 65 |
| 6.2                | 未来工作展望 .....         | 66 |
| 致 谢                | .....                | 67 |
| 参考文献               | .....                | 68 |
| 攻读硕士学位期间发表的论文及科研成果 | .....                | 72 |

# 第 1 章 绪论

## 1.1 研究背景与意义

随着信息技术和互联网的迅猛发展，网络已经深度融入社会运行与人民生活的各个方面，成为支撑经济发展、社会治理和公共服务的重要基础设施。教育、金融、医疗、政务、工业互联网等关键领域对网络的依赖程度不断提高，网络空间已成为国家和社会稳定的重要组成部分。与此同时，网络规模持续扩大，网络流量呈现出高速增长、多样化和高度动态化的特征，使网络运行环境日益复杂。根据中国互联网络信息中心（CNNIC）发布的统计数据<sup>[1]</sup>，我国网民规模和互联网普及率持续攀升，如图1-1所示，网络基础设施和在线应用的快速发展带来了海量数据交换和频繁的业务交互，为网络流量分析与管理提出了更高要求。




图 1-1 中国网民规模和互联网普及率（2023-2025 年）

在网络快速发展的同时，网络安全威胁也呈现出数量激增和形态演化的趋势。传统以单点漏洞利用为主的攻击方式逐渐向多阶段、跨平台、隐蔽性强的高级持续性威胁（APT）演进，分布式拒绝服务攻击（DDoS）、供应链攻击、恶意软件传播和针对关键基础设施的定向攻击频繁发生。这类攻击往往通过异常的连接行为、突发流量、通信模式变化或持续性隐蔽通信体现出来，对金融系统、能源系统、交通系统和政务网络造成严重威胁。网络攻击不仅会导致网络服务中断和经济损失，还可能引发社会秩序和国家安全风险，因此对网络异常行为的及时识别与预警已成为网络安全防护体系中的核心任务。

网络流量作为用户通信行为和网络运行状态的直接反映，是发现安全威胁和异常行为的重要数据基础。通过对流量特征、时序变化和通信模式的分析，可以揭示网络中潜

在的攻击活动、异常访问和资源滥用现象。异常网络流量检测技术因此成为入侵检测系统、态势感知平台和网络安全运维的重要组成部分。然而，随着网络规模的扩大和应用类型的多样化，传统基于规则匹配和特征签名的检测方法逐渐暴露出局限性。这类方法高度依赖人工构建的规则库和已知攻击特征，对未知攻击和变种攻击的适应能力不足，在高维、大规模和高速流量环境中还面临着实时性和可扩展性问题。与此同时，加密流量比例的不断上升使得基于内容特征和载荷分析的传统检测手段进一步受限，仅依靠协议字段和浅层特征已难以有效刻画复杂的通信行为。

在实际网络环境中，大规模流量数据往往缺乏精确标注，异常样本稀少且分布不均，这使得依赖标签数据的监督学习方法在训练成本、模型泛化能力和实际部署方面受到制约。相比之下，无监督学习方法能够在无需人工标注的条件下，从大量未标注流量中自动学习正常通信行为的统计规律和结构特征，并将偏离这些规律的流量识别为异常，在未知攻击检测和动态网络环境中具有更强的适应能力。近年来，自编码器、聚类方法、孤立森林以及基于深度表示学习的无监督模型在异常检测领域取得了显著进展，为复杂网络流量建模和异常识别提供了新的技术路径。

同时，准确可靠的异常流量检测技术对于网络资源调度、负载均衡和服务质量保障也具有重要意义。通过对异常流量的实时发现与预警，可以有效避免网络拥塞、服务中断和性能下降，为网络运维与安全管理提供科学依据。更进一步，随着数字经济、工业互联网和智慧城市建设的不断推进，构建高效、自适应的异常网络流量检测体系，对于保障关键信息基础设施安全、维护国家网络空间安全和支撑社会数字化运行具有重要的战略价值。

在此背景下，开展基于无监督学习的异常网络流量检测研究，不仅有助于突破传统规则驱动和监督学习方法在复杂网络环境中的局限，而且能够有效应对标签匮乏、攻击多样化和加密流量普及等现实挑战。通过对网络流量的时序特征、统计特性和行为模式进行深层次建模，可以在无需依赖已知攻击样本的情况下发现潜在威胁，提高对新型攻击、变种攻击和隐蔽通信的检测能力，从而提升网络安全防护的智能化和自动化水平。在复杂真实网络环境中，异常网络流量检测面临着若干关键技术瓶颈，其中尤以异常样本稀缺和未知攻击难以识别最为突出。

(1) 异常样本稀少且标注困难的问题。在实际网络运行过程中，绝大多数流量属于正常业务通信，而异常流量通常只在攻击发生或系统异常时短暂出现，具有低发生率和强不平衡性的特点。此外，异常流量的精确标注往往依赖于安全专家对网络日志、流量行为和攻击过程的综合分析，不仅人工成本高，而且在加密通信和复杂业务环境下难以保证标注的一致性与准确性。这使得大规模、高质量的标注异常流量数据难以获得，导致基于监督学习的检测方法在训练阶段容易出现过拟合或泛化能力不足的问题，难以适应真实网络环境中不断变化的流量分布。

(2) 未知攻击与变种攻击难以有效检测的问题。现有多数异常流量检测和入侵检测方法依赖于历史攻击样本或预定义特征规则，对已知攻击类型具有较好的识别能力，但

当攻击者采用新的攻击手段、变更攻击特征或利用零日漏洞时，这类方法往往失效。随着 APT 攻击、分布式协同攻击和隐蔽通信技术的不断发展，攻击行为呈现出低频化、持续化和高度隐蔽的特征，仅基于已知样本或静态规则构建的模型难以准确刻画其行为模式，容易造成漏报和误报，从而削弱网络安全防御体系的有效性。

正是在上述两方面挑战的共同作用下，基于无监督学习的异常网络流量检测方法逐渐成为研究热点。无监督学习无需依赖人工标注的异常样本，而是通过对大量正常网络流量的统计特征和时序行为进行建模，自动学习正常通信模式的内在分布结构，从而将偏离该分布的流量判定为异常。这种以“正常行为建模”为核心的检测机制，使模型在面对异常样本稀缺和未知攻击频繁出现的情况下仍具有较强的鲁棒性和泛化能力，能够更好地适应复杂、动态和开放的网络环境。

综上所述，基于无监督学习的异常网络流量检测研究在理论上有助于推动机器学习与网络安全领域的交叉融合，在技术上能够提升对未知威胁的识别能力，在工程应用和国家安全层面则为构建智能化、可靠的网络安全防御体系提供重要支撑，因此具有显著的学术意义和现实价值。

## 1.2 国内外研究现状

### 1.2.1 异常流量检测研究现状

随着互联网规模的不断扩大和网络应用场景的日益复杂，网络异常流量检测已成为网络安全领域的重要研究方向。网络异常流量检测的核心目标是在海量网络流量数据中及时、准确地识别异常或恶意行为，从而保障网络系统的安全与稳定运行。从研究范式上看，异常流量检测通常被视为一种分类或异常识别问题，其技术手段经历了由统计分析方法、传统机器学习方法向深度学习与集成学习方法不断演进的发展过程。

早期的网络异常流量检测方法主要基于统计学原理，通过分析网络流量的统计特征（如包大小、延迟、协议分布等）来识别异常行为。该类方法通常依赖于对历史正常流量的建模，并通过设定阈值判断当前流量是否异常。典型研究如基于置信度滤波、阈值判别及流量容量建模的方法，在检测 DDoS 攻击和蠕虫病毒等显著异常行为方面取得了一定成效。统计方法计算简单、实现成本低，但对复杂攻击和新型未知威胁的检测能力有限，且对阈值设定和历史数据依赖较强，适应性不足。

网络异常流量检测逐渐向高维特征建模、时序关联学习和无监督检测方向发展。相较于早期依赖人工特征和规则的方法，研究者更加关注模型对复杂攻击行为和未知威胁的适应能力。在无监督异常检测方面，自编码器仍是研究热点之一。Park 等人提出面向网络数据包的无监督异常检测模型<sup>[2]</sup>，仅利用正常流量进行训练，通过对抗训练降低模型对异常流量的重构能力。实验结果表明，该方法在保持较高检测精度的同时，大幅减少模型参数量，具备较好的实时检测潜力。然而，该类方法仍容易受到噪声特征和阈值设定的影响。

为进一步挖掘网络流量中的时序与空间特征，研究者开始将卷积神经网络与循环神经网络进行融合。Mirsky 等人提出了基于自编码器的无监督网络入侵检测系统 Kitsune<sup>[3]</sup>，该方法通过多层自编码器对网络流量的正常行为进行建模，并利用重构误差实现异常检测。实验结果表明，该模型在无需攻击标签的情况下，能够有效检测多种网络攻击行为，在多种真实网络环境中表现出较高的检测准确率和良好的实时性。Lansky 等人<sup>[4]</sup>对近年来深度学习入侵检测方法进行了系统评估，指出时空特征融合模型在复杂攻击识别方面具有明显优势，但模型结构复杂、计算成本较高。

随着注意力机制的发展，Transformer 模型逐渐被引入网络异常流量检测领域。Shi 等人<sup>[5]</sup>将 Transformer 与 BiLSTM 相结合，实现全局特征建模与时序依赖学习的协同优化，在不平衡数据场景下表现出更强的检测能力。Tuli 等人提出了一种基于 Transformer 的无监督异常检测模型 TranAD<sup>[6]</sup>，该方法利用自注意力机制对时间序列数据进行建模，能够有效捕捉网络流量中的长期依赖关系和关键特征模式。实验结果表明，Transformer 结构在复杂时序异常检测任务中具有较强的特征建模能力，为网络流量异常检测提供了新的建模思路。然而，此类模型通常对计算资源依赖较强，限制了其在实际网络环境中的部署。

部分研究开始探索将图结构建模引入无监督异常检测任务中。Ding 等人提出了基于图自编码器的异常检测模型 DOMINANT<sup>[7]</sup>，通过联合建模节点属性与图结构信息，实现对异常节点的无监督检测。实验结果表明，该方法在复杂关系数据中具有较好的检测性能和泛化能力，为将网络流量建模为图结构并开展异常检测提供了有效思路。此外，Zerveas 等人提出了一种基于 Transformer 的自监督表示学习框架，通过对多变量时间序列进行自监督训练，有效提升了模型在不同数据分布下的泛化能力<sup>[8]</sup>。相关研究表明，将自监督学习与 Transformer 结构相结合，有助于缓解跨数据集场景中模型性能下降的问题，该思想同样适用于网络入侵检测等复杂时序建模任务。

已有研究表明，基于自动化机器学习（AutoML）的数据驱动方法能够有效提升入侵与异常检测的性能。Xu 等人提出了一种面向物联网环境的 AutoML 入侵检测方法，通过自动化模型选择与参数优化构建检测模型，在保证检测准确率的同时增强了模型的鲁棒性与泛化能力<sup>[9]</sup>。Ozcelebi 等对随机森林、XGBoost 和 LightGBM 等方法在 CIC-IDS-2017 上进行了比较，发现集成模型在不平衡情况下表现出色<sup>[10]</sup>。在复杂场景中，注意力增强型 LSTM 与梯度提升类集成策略结合也被证明具有提升稀有攻击检测能力的潜力<sup>[11]</sup>。此外，近期研究表明，通过将特征选择机制与集成学习框架相结合，能够进一步提升入侵检测模型在不同数据集下的稳定性与泛化性能。Injadat 等人提出了一种融合混合特征选择与集成学习的入侵检测方法，通过筛选关键特征并组合多种分类器，在多个基准数据集上验证了该方法在检测准确率和鲁棒性方面的优势<sup>[12]</sup>。

总体而言，当前网络异常流量检测研究已从基于规则和统计的方法逐步发展到以机器学习、深度学习和集成学习为核心的智能检测阶段。尽管现有方法在检测精度和适应性方面取得了显著进展，但在对未知攻击的鲁棒检测、异常样本稀少、特征选择自动化

以及模型复杂度控制等方面仍存在不足。因此，设计兼顾检测性能、计算效率和泛化能力的异常流量检测方法，仍是该领域亟需深入研究的重要方向。

### 1.2.2 基于异常流量检测的机器学习方法

基于异常流量的机器学习方法通过对网络流量数据进行建模与分析，实现对正常行为模式与异常行为模式的区分，是当前网络安全领域中应用最为广泛的异常检测技术之一。该类方法通常以网络流量的统计特征、行为特征或时序特征作为输入，通过机器学习算法对流量进行训练与判别，从而实现对异常流量的自动识别。根据是否依赖人工标注数据以及模型结构的不同，基于异常流量的机器学习方法主要可分为有监督学习方法、无监督学习方法<sup>[13]</sup>以及基于深度学习的方法。

(1) 基于有监督学习的异常流量检测方法有监督学习方法依赖于大量已标注的网络流量数据，通过学习正常流量与异常流量之间的差异，构建分类模型以实现异常检测<sup>[14]</sup>。常见的有监督学习算法包括支持向量机（Support Vector Machine, SVM）、决策树、随机森林、K近邻算法以及朴素贝叶斯等。这类方法通常具有较高的检测精度和较强的判别能力，尤其在已知攻击类型和标签较为完备的情况下，能够取得较为理想的检测效果。然而，在实际网络环境中，异常流量样本往往数量有限且标注成本较高，容易导致数据集类别不平衡问题，从而影响模型的泛化能力。因此，有监督学习方法在应对未知攻击或新型异常流量时存在一定局限性。

(2) 基于无监督学习的异常流量检测方法无监督学习方法不依赖人工标注数据，而是通过挖掘网络流量数据的内在结构和分布特征，自动识别偏离正常模式的异常行为<sup>[15]</sup>。该类方法通常假设正常流量在特征空间中具有较高的相似性，而异常流量则表现为离群点或低概率事件。典型的无监督学习算法包括聚类算法（如K-means、层次聚类）、密度估计方法以及基于概率模型的方法（如高斯混合模型）。无监督学习方法在异常标签稀缺的场景下具有较强的实用价值，能够有效发现未知异常模式，但其检测性能在一定程度上依赖于特征选择和参数设置，且对复杂、高维流量数据的建模能力有限。

(3) 基于深度学习的异常流量检测方法随着大数据与深度学习技术的快速发展，基于深度学习的异常流量检测方法逐渐成为研究热点<sup>[16]</sup>。该类方法能够通过多层非线性结构自动学习网络流量的高层特征表示，减少对人工特征工程的依赖。常见模型包括卷积神经网络（CNN）、循环神经网络（RNN）、长短期记忆网络（LSTM）以及自编码器（Autoencoder, AE）等。其中，CNN在捕捉流量空间特征方面具有优势，RNN及LSTM在处理时间序列流量数据、建模长期依赖关系方面表现突出，而自编码器则常用于基于重构误差的无监督异常检测任务。近年来，生成对抗网络（GAN）及图神经网络（GNN）也逐渐被引入异常流量检测领域，以提升模型对复杂网络结构和动态变化行为的建模能力。

总体而言，基于异常流量的机器学习方法在网络安全防护中发挥着重要作用。传统

机器学习方法在特定场景下具有较高的稳定性和可解释性，而深度学习方法在处理大规模、高维度和复杂时序流量数据方面展现出更强的表达能力。如何在检测精度、计算复杂度与实际部署成本之间取得平衡，并提升模型对未知异常流量的检测能力，仍是该领域亟待研究的重要问题。

### 1.2.3 基于异常流量检测的深度学习方法

随着网络环境的复杂化和网络攻击手段的不断演进，传统基于规则或浅层机器学习的异常流量检测方法在特征表达能力和泛化性能方面逐渐暴露出局限性。深度学习方法通过构建多层神经网络结构，能够自动从大规模网络流量数据中学习高层次、非线性的特征表示，在异常流量检测领域展现出显著优势，已成为当前研究的主流方向之一。

早期研究主要集中于将基础神经网络结构引入异常流量检测任务。例如，Devan 及其团队使用了前馈神经网络（Feedforward Neural Network, FNN）结合 XGBoost 特征选择方法，形成了 XGBoost-FNN 异常流量检测模型<sup>[17]</sup>，在 NSL-KDD 等经典数据集上取得了优于传统贝叶斯分类器和支持向量机的检测性能。同时，Ghorbani 及其团队提出了一种基于稀疏自动编码器（Sparse Auto Encoder, SAE）用于流量特征降维与表示学习<sup>[18]</sup>，其中 SAE 能够在减少特征冗余的同时保留关键判别信息，不仅提升了检测精度，还有效降低了模型训练时间。实验结果表明，SAE 的效果优于基于随机森林和主成分分析的特征降维方法，并且能够显著减少模型训练所需时间。

随着卷积神经网络（CNN）在图像领域取得突破性进展，此外，研究者提出了基于网络流量图像可视化的分类方法，通过将流量数据转换为二维图像并利用机器学习模型进行分类，从而实现对恶意流量的检测与分析。Demmesse 等人采用图像化方式将网络流量表示为灰度图或彩色图，然后基于卷积神经网络等机器学习算法对这些图像进行分类，有效提升了对隐匿性恶意流量的识别精度，展示了图像表示技术在网络流量分类与异常检测中的潜力<sup>[19]</sup>。大量实验表明，不同尺寸和构建方式的流量灰度图会对检测效果产生显著影响，合理的图像表示有助于提升模型的识别能力，尤其在僵尸网络流量和加密流量检测任务中表现突出。

针对网络流量天然具有时序特性的特点，循环神经网络（RNN）及其改进模型被广泛应用于异常流量检测。RNN 能够捕获流量数据中的时间依赖关系，但在处理长期依赖问题时存在一定不足。因此，长短期记忆网络（LSTM）和门控循环单元（GRU）逐渐成为主流选择。这类模型在 NSL-KDD、UNSW-NB15 等数据集上的实验结果表明，其在二分类和多分类任务中均优于传统 RNN 模型，能够更准确地刻画复杂攻击行为的时序特征。

随着单一深度学习模型在特征表达方面的局限性逐渐显现，研究者开始关注多模型融合的异常流量检测方法。Khan 提出了 HCRNNIDS 模型<sup>[20]</sup>，将 CNN 和 RNN 结合为 CRNN 结构，使模型能够分别学习网络流量数据的空间特征与时序关系，在 CICIDS2018

数据集上取得了 97.75% 的二分类准确率。该模型的性能优于仅使用 LSTM 或 CNN 的模型，远超传统机器学习算法的对比模型。Wu 等人设计了 ResBlk 结构<sup>[21]</sup>，将 CNN 和门控循环单元融合，并使用残差连接和批标准化技术，在 NSL-KDD 的 10 折交叉验证任务中取得了 99.21% 的二分类准确率。Sinha 等人<sup>[22]</sup>将一维 CNN 和 BiLSTM 组成堆叠模型，在多个异常流量检测数据集上进行多分类实验，实验结果显示，该堆叠模型的整体准确率和少数类别 F1 值均优于对比模型。

近年来，注意力机制的引入为异常流量检测提供了新的研究思路。通过在模型中引入通道注意力、自注意力或多头注意力机制，可以对关键流量特征进行加权，从而提升模型对重要信息的关注能力。Lan 等研究者提出了 MEMBER 模型<sup>[23]</sup>，该模型利用通道注意力机制的卷积多任务学习，在多个流量异常检测领域基准数据集上取得了较高的 F1 值。Fu 等研究者通过 BiLSTM 学习流量数据时序特征，并利用通道注意力影响特征图，大量消融实验表明了通道注意力在异常流量检测上的有效性<sup>[24]</sup>。张安琳等研究者使用自注意力机制对 CNN 和 BiGRU 提取的特征进行加权处理<sup>[25]</sup>，该方法在 CICIDS2018 数据集上的总精确率与召回率均得到提升。杨月麟等研究者提出了一种卷积神经网络与 Transformer 结合的异常检测模型<sup>[26]</sup>，并使用 CReST 类别再平衡算法解决数据集不平衡问题。在 CICIDS2017 数据集上实现了较高的准确率，同时在 DoS 和 Probe 等少数类别上的检测率与召回率优于对比模型。

随着深度学习方法的不断演进，越来越多研究将注意力机制、混合模型结构与自动学习能力引入异常流量检测中，从而显著提升了检测精度与特征自动提取能力<sup>[27]</sup>，然而，这些方法在小样本条件下的训练效率与跨场景泛化能力仍然受到挑战。为此，研究者提出了结合自注意力机制的少样本入侵检测框架来增强模型鲁棒性与跨域适应能力<sup>[28]</sup>，同时也有工作采用增量特征学习与相似性嵌入方法提升对未知攻击的实时检测能力<sup>[29]</sup>。

## 1.3 本文主要研究内容及创新

### 1.3.1 主要研究内容

本论文主要研究内容包含三个部分，如图1-2所示。第一部分，我们提出了一种基于半监督学习的二阶段页岩气井积液检测模型。该模型采用分段式设计：第一阶段通过检测积液是否存在，初步判断井筒的积液状态；第二阶段在第一阶段的基础上，进一步对积液样本的严重程度进行分级。这种分阶段的设计不仅提高了模型对积液状态的识别精度，还为排水措施的制定提供了量化依据。在模型构建过程中，我们采用了半监督学习策略，充分利用少量标注数据与大量未标注数据进行训练。该策略有效避免了大量标签制作所带来的高昂成本开销，同时借助标注数据为模型训练提供了必要的指导。此外，我们还设计了一种双注意力增强模块，该模块强化了模型对积液特征的代表能力，帮助模型实现更高的识别准确率。

第二部分，我们设计了一种基于联邦学习的页岩气井积液检测模型协同优化方法。




图 1-2 页岩气井积液检测场景下针对投毒攻击的联邦学习算法的研究架构

该方法为每个区块的积液检测模型设置了一个“局部化中心模型”。该模型将从其他区块学习到的信息经过筛选，再传递到本地积液检测模型，有效避免因区块间生产环境差异导致的模型性能下降。此外，我们还设计了一种动态双向权重调节机制，该机制包含中心化加权聚合算法和知识迁移权重调节算法两个部分。中心化加权聚合算法以本地数据为参考标准，逐步整合其他区块的信息，使积液模型在协同优化过程中保持一定个性化的同时逐步提升泛化能力。知识迁移权重调节算法则能帮助样本量较少的新开发区块从协同优化训练中获取更多有利信息。

第三部分，我们针对投毒攻击的页岩气井积液检测联邦防御算法进行了深入研究。在隐私保护方面，我们结合了差分隐私技术和生成对抗网络。在满足差分隐私加密强度的前提下，降低了差分隐私技术对积液检测模型性能的负面影响。在攻击防御方面，我们从模型投毒攻击和数据投毒攻击两个角度进行了研究。针对数据投毒，我们在知识迁移权重调节算法的基础上，结合基于注意力蒸馏的防御算法，形成了一种基于注意力蒸馏的知识迁移算法，并验证了其在页岩气井积液检测模型协同优化场景下防御数据投毒攻击的有效性。针对模型投毒，我们将拜占庭弹性聚合与中心化加权聚合相结合，形成了一种中心化弹性聚合算法，增强了积液模型在面对恶意模型参数时的稳定性。

综上所述，本研究围绕页岩气井积液检测，提出了一种融合半监督学习、联邦学习和隐私保护技术的综合解决方案。通过半监督学习的二阶段检测模型，实现了积液状态

的精准识别与分级。在此基础上，借助联邦学习的协同优化，引入“局部化中心模型”和动态双向权重调节机制，有效应对了生产环境的非均质性问题，提升了模型的泛化能力。同时，结合差分隐私技术和生成对抗网络，优化隐私保护机制，并通过基于注意力蒸馏的知识迁移算法和中心化弹性聚合算法，增强了模型对投毒攻击的防御能力。该研究将积液检测的精度提升、模型优化与隐私安全防护有机结合，为页岩气井的高效管理和安全运营提供了全面的技术支撑。

### 1.3.2 主要创新

本文创新点可总结为以下三点：

(1) 通过半监督学习结合有监督和无监督学习的优势，解决了标签数据不足问题，并采用二阶段设计进行积液检测和严重程度分级，辅以双注意力增强模块提高了模型的特征能力。

(2) 通过为每个区块的积液检测模型设置“局部化中心模型”来避免生产环境非均质引起的模型偏向性。并设计动态双向权重调节机制，帮助样本量较少的区块在协同优化过程中能够获得更多的关注。

(3) 通过生成对抗网络+差分隐私技术在数据隐私保护强度与积液检测模型性能之间取得较好的平衡。结合基于注意力蒸馏的知识迁移算法和中心化弹性聚合算法，有效识别并防御积液检测模型在联邦学习训练过程中的投毒攻击。

## 1.4 本文组织架构

**第一章：**介绍论文的研究背景、国内外研究现状及本文的主要研究内容与创新。阐述了当前井筒积液检测领域中主流的物理模型和数据驱动模型；对联邦学习技术及其最新的投毒攻击与防御研究进行了综述。

**第二章：**介绍相关技术及理论。涉及传统井筒积液检测方法和基于数据驱动的检测方法；对有监督、无监督和半监督学习策略进行了阐述；重点介绍了联邦学习中的投毒攻击及其主流防御策略，分析了这些策略的优缺点。

**第三章：**介绍基于半监督学习的二阶段页岩气井积液检测模型。详细说明了本研究所使用的数据集及数据预处理过程；展示了二阶段井筒积液分级模型的具体结构，重点介绍了双注意力增强模块；阐述了积液模型训练所采用的半监督学习流程。

**第四章：**介绍基于联邦学习的页岩气井积液检测模型协同优化方法。详细展示了利用局部化中心模型思想完成页岩气井积液检测模型协同优化训练的整体流程，重点介绍了动态双向权重调节机制，包括中心化加权聚合和知识迁移调节两个部分。

**第五章：**介绍针对投毒攻击的页岩气井积液检测联邦防御算法。评估差分隐私+生成对抗网络方法的数据隐私保护强度及其对积液检测模型性能的影响；评估基于注意力蒸馏的知识迁移算法在协同优化训练中对数据投毒攻击的防御效果；评估中心化弹性聚

合算法在协同优化训练中对模型投毒攻击的防御效果。

**第六章：**对全文进行总结与思考，并对未来研究方向进行展望。

## 第 2 章 相关技术及理论介绍

### 2.1 异常流量数据检测相关概念

传统网络异常流量检测方法经过长时间的研究与实践，已经发展得相当成熟。本节将详细阐述五种常用的网络流量检测中的相关概念，包括数据包、PCAP 接口、加密协议、相关算法等。

#### 2.1.1 数据包与 PCAP 接口

1. 数据包的定义：数据包是计算机网络中进行数据传输的基本单位，它将用户需要传输的数据与必要的控制信息（如地址、协议类型、校验信息等）按照协议规范组织在一起，使数据能够在网络中被识别、传输、转发和接收。

2. 数据包的封装过程：在发送端，用户数据按照 TCP/IP 协议体系自上而下逐层封装：应用层对数据进行初步封装；传输层将其封装为 TCP/UDP 数据段以实现端到端通信；网络层加入 IP 头部形成 IP 数据包以完成路由；数据链路层将其封装成帧；最终在物理层以比特流形式通过传输介质发送。数据封装的整体流程如图2-1所示，主要包含以下五个步骤。




图 2-1 数据封装流程

3. PCAP 的定义：PCAP（Packet Capture）接口是一种用于捕获和存储网络数据包的标准化接口与文件格式，广泛应用于网络监控、流量分析和网络安全研究等领域。它能够在网络接口处拦截经过的数据包，并向上层应用提供统一的数据访问方式。通过 PCAP 接口，网络监控工具（如 Wireshark、tcpdump）可以按照时间顺序获取网络数据包，并支持使用过滤规则对流量进行筛选，从而提高捕获效率。捕获到的数据通常以 PCAP 文件形式保存，文件由全局头和若干数据包记录组成，每条记录包含数据包的时间戳、长度信息及原始数据内容，PCAP 文件存储的信息格式如图2-2所示。在网络异常流量检测中，PCAP 接口能够完整保留原始网络通信数据，为后续的特征提取、行为分

析和模型训练提供基础数据支持。

.pcap/.cap文件结构如下：




图 2-2 PCAP 文件结构

2.1.2 网络流量数据

在网络研究中，数据包是网络中数据传输的最小离散单位，但单个数据包所包含的信息有限，且不同数据包之间在时间和通信关系上存在内在关联。为更全面地刻画网络通信行为，研究中通常采用网络流量（Network Flow）作为基本分析对象。

网络流量是指在一段时间内，具有相同五元组信息（源 IP 地址、目的 IP 地址、源端口、目的端口和传输层协议）的数据包集合。通过对原始数据包按照五元组和时间顺序进行聚合，可以将离散的数据包映射为具有明确通信语义的网络流，从而更准确地反映主机之间的通信模式和行为特征，网络流聚合过程如图2-3所示。




图 2-3 网络流聚合过程

假设在一段时间内收集了  $n$  个数据包，那么这段时间内的所有流量数据可以被定义为一个数据包集合  $P$ 。

$$\begin{aligned}
P &= \{p^1, p^2, \dots, p^n\} \\
p^i &= \{t^i, x^i, b^i\} \\
i &= 1, 2, \dots, n
\end{aligned} \tag{2-1}$$

其中  $p^i$  表示第  $i$  个数据包,  $t^i$  表示该数据包在网卡中被截获的时间戳,  $x^i$  表示该数据包的五元组信息,  $b^i$  表示该数据包除时间戳和五元组之外的其他传输信息。经过网络流聚合后, 数据包集合  $P$  可以表示为包含了  $m$  条网络流  $f^i$  的网络流集合  $F$ , 每个单独的网络流  $f^i$  中的所有数据包具有相同的五元组信息  $x^i$ , 且按照数据包的时间戳顺序排列 ( $t^1 < t^2 < \dots < t^k$ )。

$$\begin{aligned}
P = F &= \{f^1, f^2, \dots, f^m\} \\
f^i &= \{(t^1, x^i, b^1), (t^2, x^i, b^2), \dots, (t^k, x^i, b^k)\} \\
m &\leq n, k \leq n
\end{aligned} \tag{2-2}$$

其中  $P$  表示所有的数据包集合,  $F$  表示包含了  $m$  条网络流的网络流集合, 每一条网络流  $f^i$  中包含了  $k$  个数据包, 由于数据包的总数为  $n$ , 所以网络流的条数  $m$  以及每条网络流中包含的数据包数量  $k$  均不大于  $n$ 。

### 2.1.3 SSL/TLS 加密协议原理与发展

TLS (Transport Layer Security, 传输层安全协议) 是一种在传输层与应用层之间引入安全层的加密通信协议。通过在通信双方之间建立安全通道, TLS 能够在无需修改上层应用协议的情况下, 为数据传输提供机密性、完整性与身份认证保障。因此, 各类应用层协议均可在 TLS 的保护下安全运行。基于 TLS 加密机制的典型安全应用包括 HTTPS (HyperText Transfer Protocol Secure)、SMTPS (Simple Mail Transfer Protocol Secure) 以及 FTPS (File Transfer Protocol Secure) 等。

TLS 协议源于 SSL (Secure Sockets Layer) 协议。SSL 协议最初由 Netscape 公司提出, 用于解决早期互联网通信中的安全问题。随着网络环境的不断演进, SSL 协议逐渐暴露出多种安全隐患, 并在此基础上发展形成了 TLS 协议。TLS 作为 SSL 的继任协议, 在安全性、算法设计及协议结构等方面进行了持续改进, 并形成了多个版本。各版本 TLS/SSL 协议的基本发展情况如表2-1所示。

其中, SSL 1.0 仅为内部设计版本, 未正式发布; SSL 2.0 和 SSL 3.0 虽被广泛使用, 但后续被发现存在严重安全漏洞, 已逐步被弃用。TLS 1.0 在 SSL 3.0 的基础上进行了安全性增强, 而 TLS 1.1 和 TLS 1.2 进一步修复了已知缺陷并提升了加密强度, 其中 TLS 1.2 长期被广泛应用于互联网加密通信环境。TLS 1.3 作为当前较新的版本, 引入了更安全的加密算法设计, 同时移除了部分不安全特性, 在性能与安全性方面均取得了显著提升。

表 2-1 TLS 不同版本信息

| 协议      | 年份   | 描述                                      |
|---------|------|-----------------------------------------|
| SSL 1.0 | 1994 | NetScape 公司设计的 1.0 版本，未正式发布             |
| SSL 2.0 | 1995 | NetScape 公司发布的 SSL 2.0 版本，未被广泛使用        |
| SSL 3.0 | 1996 | 曾被广泛使用，但后续发现存在严重安全漏洞，逐渐被淘汰              |
| TLS 1.0 | 1999 | 基于 SSL 3.0 的升级版本，对安全性进行了重要改进，但仍存在一定安全隐患 |
| TLS 1.1 | 2006 | 针对 TLS 1.0 中部分缺陷进行了修复和改进                |
| TLS 1.2 | 2008 | 进一步增强了安全性和性能，广泛应用于互联网加密通信中              |
| TLS 1.3 | 2018 | 当前较新的版本，引入新的加密算法设计，并移除了部分不安全特性          |

在 TLS 加密通信中，握手过程是建立安全连接的关键阶段。该过程用于协商通信参数、验证通信双方身份，并生成用于后续数据传输的会话密钥。TLS 握手流程如图2-4所示，主要包括以下步骤。




图 2-4 TLS 握手流程

1. 客户端向服务器发起握手请求，发送包含所支持的 TLS 协议版本、加密算法列表以及随机数的“Client Hello”消息。
2. 服务器响应客户端请求，返回所选定的加密算法、数字证书以及随机数，并发送“Server Hello”消息。
3. 客户端对服务器提供的数字证书进行验证，验证内容包括证书签名的合法性、证书链的完整性、证书有效期以及证书吊销状态等。
4. 客户端生成一个随机数作为“PreMaster Secret”，并利用服务器公钥对其进行加密后发送给服务器。
5. 服务器使用自身私钥对接收到的加密数据进行解密，获得“PreMaster Secret”。
6. 客户端与服务器分别利用“Client Random”“Server Random”以及“PreMaster Secret”三个随机值，通过一致的算法计算生成共享会话密钥。
7. 客户端使用生成的会话密钥对“Finished”消息进行加密并发送给服务器，该消

息包含此前所有握手阶段消息的完整性校验信息。

8. 服务器同样发送加密后的“Finished”消息给客户端，用以确认握手过程的完整性与一致性。

9. 握手过程完成，通信双方基于协商生成的共享密钥建立安全连接，并开始进行加密通信。

#### 2.1.4 网络攻击类型

网络攻击是造成网络异常流量的主要原因之一。攻击行为在产生方式、通信模式以及资源消耗特征等方面，均与正常用户访问存在显著差异，从而在网络流量中表现出明显的异常特征。根据攻击目标和实现方式的不同，常见的网络攻击类型主要包括拒绝服务攻击、Web 攻击以及远程未授权访问攻击。

(1) 拒绝服务攻击 (Denial of Service, DoS) 拒绝服务攻击通过向目标服务器持续发送大量伪造或恶意请求，占用系统计算资源、网络带宽或连接队列，使服务器无法及时响应合法用户请求。此类攻击通常表现为流量规模突增、请求频率异常以及连接状态异常堆积等特征，容易引发网络延迟增加、服务中断甚至系统崩溃。常见的拒绝服务攻击方式包括 UDP 泛洪攻击、SYN 泛洪攻击以及 Land 攻击等，是异常流量检测研究中的典型攻击类型。

(2) Web 攻击 Web 攻击主要针对 Web 应用程序及其后端服务器，利用程序设计缺陷或安全机制薄弱点实施恶意操作。常见的 Web 攻击形式包括跨站脚本攻击 (XSS)、SQL 注入和跨站请求伪造 (CSRF)。此类攻击不仅可能导致网页内容被篡改、用户会话被劫持，还可能造成数据库信息泄露或非法操作。从流量特征角度看，Web 攻击往往表现为异常的请求参数、非正常访问路径以及请求行为模式的明显偏移。

(3) 远程未授权访问攻击远程未授权访问攻击是指攻击者利用系统漏洞、弱口令或暴力破解等手段，在未获得合法授权的情况下，通过远程登录方式 (如 SSH、Telnet 等) 侵入目标系统。一旦成功获取访问权限，攻击者可能在受害者不知情的情况下执行数据窃取、恶意程序植入或系统控制等破坏性操作。该类攻击在网络流量中通常表现为异常登录尝试频繁、访问时间和访问行为不符合正常用户使用习惯等特征。

## 2.2 相关算法

在网络流量分析与异常检测研究中，机器学习方法根据训练数据中标签信息的可用程度，通常可划分为有监督学习、无监督学习、半监督学习和自监督学习四种主要范式。不同学习范式在数据依赖性、建模目标及适用场景等方面存在显著差异，表2-2对这四种学习策略进行了对比总结。

表 2-2 不同学习策略的对比总结

| 维度   | 有监督            | 无监督                | 半监督          | 自监督       |
|------|----------------|--------------------|--------------|-----------|
| 数据要求 | 大量标注数据         | 无人工标注              | 少量标注 + 大量无标注 | 构造伪标签     |
| 学习目标 | 学习特征-标签映射      | 挖掘内在结构             | 提升泛化能力       | 学习通用表征    |
| 典型任务 | 分类、回归          | 聚类、降维、异常检测         | 分类、回归        | 表征学习、预训练  |
| 代表算法 | SVM、RF、CNN、RNN | K-means、DB-SCAN、AE | 自训练、标签传播     | 对比学习、掩码建模 |

### 2.2.1 有监督学习

有监督学习是一种通过输入数据与对应标签之间的关系进行训练的学习方法。在有监督学习中，训练集中的每个样本都有明确的标签，目标是根据这些已标注的样本来训练模型，使得模型能够对新的未见样本进行预测。具体来说，有标签的数据集提供了输入数据和对应的目标值。模型根据这些数据学习输入和标签之间的映射关系。训练完成后，模型用于对新样本进行预测，生成预测标签。预测结果会与真实标签进行比较，计算误差，并使用误差反向传播来优化模型。有监督学习的特点在于训练数据必须包含标签信息，其目标通常是分类或回归任务，并通过优化损失函数来调整模型。训练过程中模型通过最小化预测值与真实标签之间的误差来学习。

### 2.2.2 无监督学习

无监督学习是一种特殊训练方法，在这种方法中，训练数据没有标签。模型通过分析数据中的结构、分布、聚类等模式来学习。无监督学习的目标是发现数据的潜在结构或特征，而不是依赖于已知的标签信息。具体来说，模型从没有标签的数据中提取数据的结构、模式、分布等信息。常见的方法包括聚类、降维、生成模型等。在许多无监督学习应用中，预测阶段可能不涉及明确的标签预测，而是着重于从数据中发现新颖的模式或特征，如群体结构、异常点检测、数据降维等。无监督学习的特点在于不需要人工标注数据，训练数据中没有目标标签。目标通常是对数据进行探索，发现其潜在结构。适用于无法获取标注数据或标注成本高的场景。

### 2.2.3 半监督学习

半监督学习是一种结合了有监督学习和无监督学习的机器学习方法，它在训练过程中既利用了少量的标签数据，也利用了大量的未标注数据。其目标是通过已标注数据和未标注数据的结合，来提高模型的性能，特别是在标注数据稀缺的情况下。具体来说，

半监督学习模型首先利用少量的标注数据进行训练，然后通过聚类、生成模型等方法将未标注数据的结构或模式信息引入模型。和有监督学习类似，经过训练后，模型可以使用已标注数据和未标注数据提取到的知识，对新样本进行预测。半监督学习的特点在于训练数据包含少量标签数据和大量未标注数据。相较于完全依赖标注数据，半监督学习可以显著减少标注数据的需求，节省成本。在数据标注昂贵或耗时的任务中，半监督学习是一种有效的选择。

## 2.2.4 自监督学习

自监督学习（Self-Supervised Learning, SSL）是一种通过数据自身结构生成监督信号的学习范式，它无需依赖人工标注即可从大量未标注数据中学习有效表示。尽管与半监督学习有相似之处，但自监督学习在预训练阶段完全不使用任何人工标注数据，而是通过精心设计的预训练任务（Pretext Task）来挖掘数据的内在规律。

自监督学习的核心流程包括两个阶段：预训练阶段和微调阶段。在预训练阶段，模型通过解决自监督任务（如掩码重建、对比学习、预测未来等）来学习数据的通用特征表示；在微调阶段，这些预训练得到的特征可以被迁移到下游任务（如积液检测）中，仅需少量标注数据即可获得良好的性能。

根据预训练任务的设计思路，自监督学习方法可分为三大类：

(1) **生成式方法**：通过重建原始数据或其部分内容来学习特征，如 BERT（掩码语言模型）、MAE（掩码自编码器）等。在气井数据场景中，可以通过重建掩码的生产参数（如压力、流量）来学习气井状态的关联特征。

(2) **对比式方法**：通过学习相似样本和不相似样本之间的判别性特征，如 SimCLR、MoCo 等<sup>[30]</sup>，对于气井数据，可以将同一气井在连续时间点的数据视为正样本对，不同工况的数据视为负样本对进行学习。

(3) **预测式方法**：通过预测数据的未来状态或缺失部分来学习特征，如基于时间序列预测的自监督学习。在气井积液检测中，可以预测未来的压力变化趋势，从而学习到与积液相关的时间演化特征。

自监督学习在气井积液检测领域具有显著优势。由于气井生产数据通常具有时间序列特性且标注成本高昂，自监督学习可以利用大量未标注的生产数据进行预训练，学习气井正常和异常状态的内在规律。预训练后的模型通过少量标注的积液数据进行微调，即可在积液检测任务中取得优异性能，有效降低了对大规模标注数据的依赖，为实际应用提供了更经济高效的解决方案。

## 2.3 深度学习相关理论

深度学习作为机器学习的重要发展方向，通过构建多层神经网络模型，从网络流量等大规模复杂数据中自动学习具有判别性的深层特征，在异常检测任务中展现出显著优

势。相比传统依赖人工特征设计的方法，深度学习能够有效刻画网络流量数据中潜在的非线性关系和高维特征结构，从而提升异常行为识别的准确性与鲁棒性<sup>[31]</sup>。

在网络流量异常检测研究中，卷积神经网络（CNN）通过局部连接与参数共享机制，能够挖掘流量特征之间的空间相关性，适用于流量特征表示与模式识别；循环神经网络（RNN）及其相关模型擅长建模流量数据的时间依赖特性，在序列化流量分析与行为异常检测中得到广泛应用<sup>[32]</sup>；此外，基于注意力机制的深度学习模型通过动态分配不同特征或时间片的重要性权重，有效增强了模型对关键异常特征的感知能力，为复杂网络环境下的异常流量检测提供了新的建模思路。

### 2.3.1 人工神经网络结构

人工神经网络通常由输入层、隐藏层和输出层组成，如图2-5所示，每一层由若干神经元组成。数据从输入层传递到输出层，每个神经元接收来自上一层的输入，加权求和后通过激活函数进行非线性变换再传递到下一层。假设当前层的输入向量为  $\mathbf{x} =$




图 2-5 人工神经网络结构

$[x_1, x_2, \dots, x_n]$ ，其下一层的第  $j$  个神经元的计算公式如下：

$$z_j = f\left(\sum_{i=1}^n w_{ji}x_i + b_j\right) \quad (2-3)$$

其中， $f(\cdot)$  为激活函数， $w_{ji}$  表示当前层第  $i$  个神经元到下一层第  $j$  个神经元的权重， $b$  是偏置项。

激活函数用于引入非线性因素，使神经网络能够处理复杂的非线性关系。常见的激活函数包括：

Sigmoid 函数将输入映射到 (0,1) 区间：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-4)$$

ReLU 函数在正区间保持线性，负区间输出为 0：

$$f(x) = \max(0, x) \quad (2-5)$$

tanh 函数将输入映射到 (-1,1) 区间：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-6)$$

Softmax 函数将输入映射到 (0,1) 区间，并且所有输出加和为 1，适合表示类别概率。假设下一层共有  $p$  个神经元，第  $k$  个神经元的值可以表示为：

$$f(x_k) = \frac{e^{x_k}}{\sum_{j=1}^p e^{x_j}} \quad (2-7)$$

为了度量模型预测值与真实值之间的差距，需要引入损失函数来计算损失值。常见的损失函数包括：

MSE 函数常用于回归问题：

$$L = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2-8)$$

其中， $L$  为损失值， $y$  为真实值， $\hat{y}$  为预测值， $N$  为样本数量。

交叉熵损失函数常用于分类问题：

$$L = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^p y_{ik} \log(\hat{y}_{ik}) \quad (2-9)$$

其中， $L$  为损失值， $y_k$  为 0 或 1，表示真实标签是否为第  $k$  类， $\hat{y}_k$  表模型预测为第  $k$  类的概率， $N$  为样本数量， $p$  为类别总数。

得到损失值后，通过反向传播算法来计算各层权重的梯度，然后通过梯度下降法更新权重。这里用最简单的链式法则来展示输出层的权重是如何调整的。

梯度计算：

$$\frac{\partial L}{\partial w_j} = \frac{\partial L}{\partial z_j} \cdot \frac{\partial z_j}{\partial w_j} \quad (2-10)$$

其中， $\frac{\partial L}{\partial w_j}$  为梯度， $\frac{\partial L}{\partial z_j}$  表示损失函数对第  $j$  个隐藏层神经元输入的偏导数， $\frac{\partial z_j}{\partial w_j}$  表示第  $j$  个隐藏层神经元的输入关于权重的偏导数。

梯度更新：

$$w_j = w_j - \eta \cdot \frac{\partial L}{\partial w_j} \quad (2-11)$$

其中， $w_j$  表示第  $j$  个隐藏层神经元到输出层的权重， $\eta$  为学习率。

上述公式描述了人工神经网络的基本工作原理，从数据输入到预测输出，以及通过反向传播训练模型的过程。

## 2.3.2 注意力机制

Transformer 模型主要由编码器（Encoder）和解码器（Decoder）组成，结构如图2-6所示。编码器由多个相同的层堆叠而成，每一层都包含两个主要模块：多头自注意力机制和前馈神经网络。自注意力机制允许模型在不同位置上关注输入序列的不同部分，从而捕捉序列内部的依赖关系。多头注意力机制则是将输入分成多个“头”，每个头独立计算注意力，最后将这些头的结果拼接起来，这样可以捕捉到不同子空间中的信息。每个位置的输出都会通过一个全连接的前馈神经网络进行进一步处理。该网络对每个位置的输出独立操作，不会引入位置之间的交互。




图 2-6 Transformer 模型结构<sup>[33]</sup>

解码器的结构与编码器类似，其自注意力机制会额外使用掩码（Mask），只允许模型关注当前及之前的位置，从而避免解码器在生成序列时看到未来的信息。解码器的输出最终通过一个线性层和 softmax 函数，生成目标序列的概率分布。

注意力机制（Attention Mechanism）是 Transformer 模型的核心部件，计算输入序列中各个元素的重要性权重，并将这些权重应用于输入数据，生成一个加权的上下文表示。具体来讲，需要计算每个输入元素相对于某个查询向量的重要性分数，以点积注意力为例，给定一个查询向量  $q$  和输入序列  $X$ ，每个元素  $x_i$  的注意力分数计算如下：

$$\text{score}(q, x_i) = q^T x_i \quad (2-12)$$

其中， $q^T$  表示查询向量的转置，点积操作的结果是一个标量，表示查询向量与输入元素  $x_i$  之间的相似度。

接下来，将注意力分数通过一个归一化函数转换为注意力权重，使得所有权重的和

为 1。这样可以确保每个权重都在  $[0,1]$  范围内，并且权重的总和为 1。

$$\alpha_i = \frac{\exp(\text{score}(q, x_i))}{\sum_{j=1}^n \exp(\text{score}(q, x_j))} \quad (2-13)$$

其中， $\alpha_i$  表示第  $i$  个输入元素的注意力权重， $\exp$  是指数函数，用于将分数转换为正值。

最后，根据计算得到的注意力权重，对输入序列进行加权求和，生成上下文表示：

$$c = \sum_{i=1}^n \alpha_i x_i \quad (2-14)$$

其中， $c$  是一个加权的向量，表示输入序列中与查询向量最相关的信息。这个上下文表示可以用于后续的任务，如翻译、分类或生成。

上述公式描述了注意力机制的完整计算过程。

### 2.3.3 损失函数

在网络流量异常检测任务中，损失函数用于度量模型预测结果与真实标签之间的偏差，是深度模型参数优化的核心依据。鉴于网络流量数据普遍存在类别分布不均衡、异常样本比例低以及流量模式复杂多变等特点，本文重点关注分类损失、不均衡优化损失以及异常检测专用损失三类，与后续模型设计保持一致。

#### (1) 分类损失函数

交叉熵损失（Cross Entropy, CE）是网络流量异常检测中最常用的分类损失函数，广泛应用于正常流量与异常流量的二分类或多分类任务。其通过最小化预测分布与真实标签分布之间的差异，引导模型学习具有判别性的流量特征。其数学形式定义如下：

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{ic} \log(\hat{y}_{ic}) \quad (2-15)$$

其中， $N$  表示样本数量， $C$  为类别数， $y_{ic}$  为样本  $i$  在类别  $c$  上的真实标签， $\hat{y}_{ic}$  为模型预测概率。由于网络流量数据中异常样本通常占比较低，直接采用交叉熵损失易导致模型偏向正常流量类别，从而影响异常检测召回率。

#### (2) 不均衡优化损失函数

针对网络流量异常检测中普遍存在的类别不均衡问题，研究中常采用加权交叉熵损失或 Focal Loss 以增强模型对异常流量的关注能力。加权交叉熵（Weighted Cross Entropy, WCE）通过为不同类别分配权重，降低多数类样本对整体损失的主导作用，其定义如下：

$$\mathcal{L}_{WCE} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C \omega_c y_{ic} \log(\hat{y}_{ic}) \quad (2-16)$$

其中， $\omega_c$  为类别  $c$  对应的权重，通常为异常流量类别设置更大的权重值，以提升模型对少数异常样本的识别能力。Focal Loss 在交叉熵损失的基础上引入调制因子，使模型

更加关注难以分类的样本，其数学形式为：

$$\mathcal{L}_{\text{FL}} = -\frac{1}{N} \sum_i i = 1^N \sum_{c=1}^C (1 - \hat{y}_{ic})^\gamma y_{ic} \log(\hat{y}_{ic}) \quad (2-17)$$

其中， $\gamma$  为聚焦参数，用于控制对易分类样本的抑制程度。在网络流量异常检测中，Focal Loss 能有效提升对隐蔽异常流量的检测性能。

### (3) 异常检测专用损失函数

在无监督或半监督网络流量异常检测场景中，自编码器（Autoencoder, AE）及其变体通常以重构损失作为训练目标，假设模型主要学习正常流量的特征分布，从而使异常流量在重构阶段产生较大的误差。常用的重构损失定义如下：

$$\mathcal{L}_{\text{rec}} = \frac{1}{N} \sum_i i = 1^N |x_i - \hat{x}_i|_2^2 \quad (2-18)$$

其中， $x_i$  与  $\hat{x}_i$  分别表示输入流量特征与模型重构结果。在检测阶段，通过对重构误差设置阈值即可实现异常流量判别。相较于监督方法，基于重构损失的异常检测模型在未知攻击或新型异常检测任务中具有更好的泛化能力。

## 2.3.4 注意力机制

注意力机制是一种用于增强模型对输入序列中重要部分的关注的机制。它通过计算每个输入元素的权重，将这些权重与输入元素进行加权求和，从而生成一个上下文表示。注意力机制在自然语言处理、语音识别、图像识别等领域取得了显著的成功。在联邦学习中，注意力机制可以用于增强模型对不同参与方数据的关注，从而提高模型的鲁棒性与跨域适应能力。

## 2.4 系统开发设计基础

### 2.4.1 FastAPI 框架

FastAPI 是一个基于 Python 的 Web 框架，用于构建快速的 API。它基于 Starlette 框架，提供了快速的路由、请求处理和响应生成。FastAPI 的主要优势在于其快速的性能和自动生成的 API 文档。它还支持异步请求处理，这使得它在处理高并发请求时表现出色。在本研究中，我们使用 FastAPI 框架构建了一个简单的 API，用于接收生产数据并返回预测结果。

### 2.4.2 Kafka

Kafka 是一个分布式流处理平台，用于构建实时数据管道和流应用程序。它可以用于处理高吞吐量的实时数据，例如网络流量、传感器数据等。Kafka 的主要优势在于其

高吞吐量、低延迟和高可扩展性。在本研究中，我们使用 **Kafka** 作为数据管道，将生产数据从传感器发送到模型进行预测。

### 2.4.3 Elasticsearch

**ElasticSearch** 是一个基于 **Lucene** 的搜索引擎，用于存储、搜索和分析大量数据。它可以用于存储网络流量数据，例如从传感器收集的生产数据。**ElasticSearch** 的主要优势在于其快速的搜索速度和可扩展性。在本研究中，我们使用 **ElasticSearch** 作为数据存储，将生产数据从传感器发送到模型进行预测。

### 2.4.4 Zeek

**Zeek** 是一个开源的网络分析框架，用于检测和分析网络流量。它可以用于检测网络中的异常流量，例如 **DDoS** 攻击、端口扫描等。**Zeek** 的工作原理是将网络流量分成多个数据包，然后对每个数据包进行分析。分析结果可以用于检测异常流量，例如检测到异常流量后可以触发警报。**Zeek** 还可以用于分析网络流量，例如分析网络流量的协议、端口、IP 地址等。**Zeek** 的分析结果可以用于网络管理和安全监控。目前，**Zeek** 被广泛用于网络安全领域，例如检测和分析网络攻击、网络流量分析等。

## 2.5 本章小结

本章围绕网络异常流量检测研究所涉及的关键技术与理论基础展开系统介绍。首先，从数据层面阐述了数据包、PCAP 接口及网络流量的基本概念，分析了数据包封装过程以及网络流量的聚合机制，为后续流量特征建模提供了数据基础。

随后介绍了 **SSL/TLS** 加密协议的原理与发展历程，并结合常见网络攻击类型，分析了异常流量在实际网络环境中的典型表现形式。在此基础上，对有监督、无监督、半监督和自监督等主要机器学习范式进行了对比说明，并进一步介绍了深度学习相关理论，包括人工神经网络结构、注意力机制及常用损失函数，为模型设计与优化提供理论支撑。

最后，简要说明了系统实现中涉及的 **FastAPI**、**Kafka**、**ElasticSearch** 和 **Zeek** 等关键技术框架。通过本章的论述，为后续网络异常流量检测模型的构建与实验分析奠定了理论与技术基础。

## 第 3 章 基于实例多样性加权的无监督超球体学习方法

### 3.1 引言

在网络流量异常检测任务中，无监督学习方法通常假设正常流量在特征空间中具有紧凑的分布，而异常流量则分布在远离密集区域的稀疏空间。然而，在真实的工业互联网或企业网络环境中，**数据不平衡 (Data Imbalance)** 问题不仅存在于正常与异常样本之间，更广泛存在于正常流量内部<sup>[34]</sup>。

正常业务流量往往呈现出显著的**长尾分布 (Long-tailed Distribution)** 特征：绝大多数流量由高频、模式单一的背景流量（如心跳包、周期性轮询）组成，这类样本构成了分布的“头部”；而少量的关键业务操作（如大文件传输、特定数据库查询）虽然发生频率低，但模式多样且离散，构成了分布的“尾部”。

传统的基于距离的单类分类方法（如 SVDD、自编码器）在优化过程中，往往被“头部”样本主导，导致学习到的超球体中心过度偏向高密度区域，从而无法覆盖“尾部”的稀疏正常样本。这导致那些稀有但正常的合法流量被错误识别为异常，引发高误报率。

针对上述问题，本章提出一种基于实例多样性加权的无监督超球体学习方法 (Diversity-Weighted Self-Supervised Hypersphere Learning)。该方法引入**实例欧氏距离 (Instance Euclidean Distance, IED)** 作为无监督的多样性度量指标，并构建了多样性感知加权损失函数，旨在平衡不同频次正常模式对模型训练的贡献，从理论层面解决长尾分布带来的检测偏差问题。

### 3.2 长尾分布问题分析与实例多样性度量

#### 3.2.1 无监督异常检测中的长尾分布特性

假设训练数据集  $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$  仅包含正常流量样本。在理想情况下，所有样本  $x_i$  应均匀分布在某个紧凑的流形空间上。然而，在实际网络环境中，样本的分布密度  $\rho(x)$  往往呈现出显著的不均衡特性。

因此，可以将正常样本集合进一步划分为两个子集：

- **高频正常样本集 (Head Set,  $\mathcal{H}$ )**：该部分样本数量庞大，在特征空间中分布密集，其样本密度较高，即  $\rho(x)$  较大，通常满足  $|\mathcal{H}| \gg |\mathcal{T}|$ 。
- **长尾正常样本集 (Tail Set,  $\mathcal{T}$ )**：该部分样本数量较少，在特征空间中呈稀疏分布状态，其对应的样本密度较低，即  $\rho(x)$  较小。

主流的自监督或无监督异常检测模型通常致力于最小化样本特征  $\phi(x)$  到特征中心

$c$  之间的距离，其通用目标函数可表示为：

$$\mathcal{L}_{\text{base}} = \frac{1}{N} \sum_{i=1}^N \|\phi(x_i) - c\|^2. \quad (3-1)$$

由于高频正常样本集合  $\mathcal{H}$  的样本数量  $N_{\mathcal{H}}$  远大于长尾样本集合  $\mathcal{T}$  的样本数量  $N_{\mathcal{T}}$ ，在最小化整体损失的过程中，模型的梯度更新方向将不可避免地受到  $\mathcal{H}$  集合的主导。

由此带来如下三方面问题：

- **中心偏移 (Center Bias)**：特征中心  $c$  会被大量高频样本强行拉向其几何中心位置，难以兼顾分布稀疏但语义合理的正常样本。
- **边界收缩 (Boundary Shrinking)**：为适配高密度区域样本，模型倾向于缩小超球体半径  $R$ ，从而使决策边界过度贴合主流样本分布。
- **尾部丢失 (Tail Missing)**：属于长尾集合  $\mathcal{T}$  的正常样本往往位于超球体边界之外，其异常得分 (Anomaly Score) 被显著放大，从而被错误判定为异常样本，产生较高的误报率。




图 3-1 传统损失函数与加权损失函数差异

如图 3-1 所示，传统损失函数与加权损失函数在处理不平衡数据时呈现出明显差异：左图中，传统方法学习得到的中心点紧贴高密度样本区域，导致灰色稀疏正常样本被误判为异常；而右图所示的加权方法通过调节样本贡献权重，使特征中心适度向稀疏区域偏移，从而能够覆盖多种正常模式，有效缓解长尾样本误判问题。

为了解决上述中心偏移问题，首要任务是找到一种能够精准刻画样本处于“头部”还是“尾部”的量化指标。

### 3.2.2 基于 IED 的实例多样性度量定义

为有效缓解长尾分布对模型训练带来的不利影响，首先需要在无监督条件下构建一种能够刻画样本“稀缺性”或“多样性”的度量指标。为此，本文引入实例欧氏距离

(Instance Euclidean Distance, IED)，用于量化样本在特征空间中的局部密度特征。

对于给定样本  $x_i$ ，其 IED 值定义为该样本与其在特征空间中  $k$  个最近邻样本的平均欧氏距离<sup>[35]</sup>。数学表达式如下：

$$D_{IED}(x_i) = \frac{1}{k} \sum_{x_j \in \mathcal{N}_k(x_i)} \|\phi(x_i) - \phi(x_j)\|_2 \quad (3-2)$$

其中， $\mathcal{N}_k(x_i)$  表示样本  $x_i$  的  $k$  近邻集合， $\phi(\cdot)$  为特征提取网络。

基于上述数学定义，IED 的物理意义可以从样本在特征空间中的分布密度角度进行解读。IED 值的大小直接刻画了样本所处的局部密度区域，为区分不同重要性的正常流量提供了量化依据。具体而言，IED 值反映了样本在正常流量分布中的位置特征，从而揭示了不同样本对模型学习的贡献度差异。具体表现如下：

- **低 IED 值：**表示  $x_i$  位于高密度区域，周围样本相似度高，属于“高频正常模式”（Head）。这类样本包含的信息冗余度较高。

- **高 IED 值：**表示  $x_i$  位于低密度区域，周围样本较少，属于“长尾正常模式”（Tail）。这类样本虽然稀少，但代表了正常业务的多样性，对界定正常行为的边界至关重要。

通过 IED 指标，我们可以在无监督的情况下，有效区分出哪些样本是需要模型“重点关注”的稀有正常流量。

### 3.3 基于 IED 加权的超球体模型构建与算法实现

在明确了 IED 作为多样性度量指标的基础上，本节构建基于实例加权的自监督超球体学习模型。该模型的核心思想是通过动态调整不同分布密度下样本的负反馈压力，引导特征空间中的超球体边界进行自适应扩张，从而保护长尾分布下的正常样本不被误判。

#### 3.3.1 模型整体框架设计

本章提出的方法由三个核心功能模块组成如图3-2所示，旨在实现从原始流量特征到具备多样性感知能力的异常度量空间的映射：

- (1) **特征学习模块：**利用深度神经网络将原始高维流量数据  $x$  映射至低维隐空间特征  $z = \phi(x; \Theta)$ ，通过自监督学习任务捕获流量的非线性流形结构。

- (2) **多样性评估模块：**在每个训练批次（Mini-batch）中，利用 IED 指标实时评估样本的局部稀缺性，识别出处于分布长尾区域的正常模式。

- (3) **损失与权重模块：**根据 IED 指标生成的权重因子  $w$ ，对损失函数进行加权更新，修正特征中心偏移并优化超球体边界。

- (4) **中心建模模块：**利用上一步生成的实例权重  $w$  计算当前批次的加权质心，并通过指数滑动平均（EMA）策略平滑更新全局特征中心，从而主动纠正由高频样本主导的中心偏移，确保决策边界有效包容稀疏的长尾正常模式。




图 3-2 IED 加权的超球体模型整体框架设计

### 3.3.2 多样性感知权重生成机制

由于不同网络环境下的特征尺度存在差异，原始的 IED 值无法直接应用于梯度优化。本模型设计了一种基于非线性映射的权重生成机制，旨在指数级放大长尾样本对模型边界界定的贡献。

首先，对当前批次内的 IED 值进行归一化处理：

$$\hat{D}_i = \frac{D_{IED}(z_i) - \min(D_{batch})}{\max(D_{batch}) - \min(D_{batch}) + \epsilon} \quad (3-3)$$

其中  $\epsilon$  为极小常数以保证数值稳定性。随后，引入多样性敏感系数  $\beta$ ，通过指数映射函数生成最终的训练权重  $w_i$ ：

$$w_i = \exp(\beta \cdot \hat{D}_i) \quad (3-4)$$

通过该机制，当  $\beta > 0$  时，分布越稀疏的样本（ $\hat{D}_i$  越大）将获得显著提高的权重，从而迫使模型在最小化全局损失时，必须同时兼顾这些边缘样本的紧凑性。

### 3.3.3 优化目标函数构建

为了实现超球体的自适应构建，本模型定义了基于多样性加权的优化目标  $\mathcal{L}_{total}$ 。该损失函数不要求预先设定超球体半径，而是通过惩罚加权后的特征距离来寻找最优的表征空间。

$$\mathcal{L}_{total} = \frac{1}{N} \sum_{i=1}^N w_i \cdot \|\phi(x_i; \Theta) - c\|^2 + \lambda \|\Theta\|^2 \quad (3-5)$$

其中,  $c$  为特征空间的全局中心,  $\lambda\|\Theta\|^2$  为参数正则化项。在训练过程中, 模型不仅更新编码器参数  $\Theta$ , 同时根据加权后的特征分布动态校正中心  $c$  的位置。

在该目标的约束下, 最优特征中心  $c^*$  的解变为样本特征的加权平均值:

$$c^* = \frac{\sum w_i \phi(x_i)}{\sum w_i} \quad (3-6)$$

从几何角度进行解释: 相比于传统方法中采用的算术平均中心, 加权中心  $c^*$  会向权重较大 (即 IED 较大的稀疏区域) 发生校正性偏移 (Center Rectification)。这种偏移使得超球体在保持对高频数据充分覆盖的同时, 能够向外 “扩张” 以接纳稀有的正常样本, 从而在不降低召回率的前提下, 显著提升了系统的检测精确率。

在实际的批次训练 (Mini-batch Training) 过程中, 为保证特征中心更新的稳定性并避免受到单个批次采样偏差的影响, 本文采用基于权重的滑动平均策略 (Exponential Moving Average, EMA) 对特征中心  $c$  进行迭代更新, 其更新公式定义如下:

$$c_t \leftarrow (1 - \alpha) c_{t-1} + \alpha \cdot \Delta c_{\text{batch}} \quad (3-7)$$

其中,  $\Delta c_{\text{batch}}$  表示当前训练批次的局部加权中心:

$$\Delta c_{\text{batch}} = \frac{\sum_{i \in \mathcal{B}} w_i \cdot z_i}{\sum_{i \in \mathcal{B}} w_i} \quad (3-7)$$

式中,  $c_t$  表示第  $t$  次迭代更新后的全局特征中心,  $\alpha$  为中心更新率 (Update Rate), 通常取较小值 (如  $\alpha = 0.1$ ), 以保证中心在特征空间中的更新过程平滑且稳定;  $w_i$  为由多样性权重模块计算得到的样本权重。

该更新策略能够有效避免中心被局部批次样本主导, 使特征中心在训练过程中缓慢向长尾稀疏区域移动, 最终收敛至能够覆盖所有正常模式的全局最优位置。

算法 1 展示了基于实例多样性加权的无监督训练过程。

### 3.4 数据预处理

为了全面验证模型在真实复杂运维环境下的泛化能力与鲁棒性, 本文选用了两个在多变量时间序列异常检测领域广泛使用的基准数据集: SMD (Server Machine Dataset) 和 PSM (Pooled Server Metrics)。

其中, SMD 数据集来源于某大型互联网公司的真实服务器集群监控系统, 涵盖了为期 5 周的连续监控记录, 包含 CPU 负载、内存使用率、磁盘 I/O 及网络流量等 38 个维度的性能指标。PSM 数据集则采集自 eBay 内部的应用服务器节点, 包含了 25 个维度的关键系统监控指标。这两个数据集均属于典型的高维多变量时间序列数据, 且内部包含大量非平稳的系统噪声与复杂的长尾分布模式, 能够充分检验本文所提 IED 加权方法在处理真实世界长尾流量时的有效性。

尽管数据集经过了初步整理, 但由于生产环境中服务器宕机、网络波动、采集探针故障等不可抗力因素, 原始数据中仍不可避免地存在噪声干扰、数据丢失及非逻辑性数

**Algorithm 1:** 基于多样性加权的无监督超球体训练算法**Require:** 训练数据集  $\mathcal{X}$ , 迭代次数  $T$ , 学习率  $\eta$ , 敏感系数  $\beta$ , 动量因子  $\gamma$ **Ensure:** 优化后的参数  $\Theta$ , 校正后的特征中心  $c^*$ 

```

1: 初始化编码器参数  $\Theta$  及随机特征中心  $c$ ;
2: for  $t = 1$  to  $T$  do
3:   从  $\mathcal{X}$  中随机采样一个批次  $\mathcal{B} = \{x_1, x_2, \dots, x_n\}$ ;
4:   计算特征表示:  $Z_{\mathcal{B}} = \{z_i = \phi(x_i; \Theta) \mid x_i \in \mathcal{B}\}$ ;
5:   {多样性评估}
6:   for all  $z_i \in Z_{\mathcal{B}}$  do
7:     计算  $k$ -最近邻平均欧氏距离  $D_{IED}(z_i)$ ;
8:   end for
9:   {权重生成}
10:  根据公式计算归一化权重  $w_i = \exp(\beta \cdot \hat{D}_i)$ ;
11:  {模型优化}
12:  计算加权损失  $\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum_{z_i \in Z_{\mathcal{B}}} w_i \|z_i - c\|^2$ ;
13:  执行反向传播并更新参数:  $\Theta \leftarrow \Theta - \eta \nabla_{\Theta} \mathcal{L}$ ;
14:  {中心校正更新}
15:   $c \leftarrow (1 - \gamma)c + \gamma \frac{\sum w_i z_i}{\sum w_i}$ ;
16: end for
17: return  $\Theta, c$ ;

```

表 3-1 实验数据集统计信息

| 数据集 | 维度 ( $D$ ) | 训练集样本数 ( $N_{\text{train}}$ ) | 测试集样本数 ( $N_{\text{test}}$ ) | 总样本数      | 划分比例 |
|-----|------------|-------------------------------|------------------------------|-----------|------|
| SMD | 38         | 708,405                       | 708,420                      | 1,416,825 | 1:1  |
| PSM | 25         | 132,481                       | 87,849                       | 220,330   | 6:4  |

值等问题。为了消除数据质量对 IED 加权超球体学习模型训练的负面影响，同时保留正常流量中的长尾特征，本节将按照图3-3所示的流程进行严格的数据预处理。

### 3.4.1 数据清洗

数据清洗旨在剔除无效特征并修正格式错误，以确保输入数据的维度一致性与有效性。针对 SMD 数据集的特点，本文主要执行如下清洗操作：

- **静态特征剔除：** SMD 数据集中的 38 个维度对应不同的系统运行指标。在部分服务器集群中，某些指标（如未挂载磁盘的 I/O、未启用服务对应的端口流量等）在整个采集周期内始终为 0 或保持恒定不变。这类方差为 0 的特征不包含有效信息，反而会增加计算冗余并干扰距离度量过程。因此，对于任意特征维度  $j$ ，若满足  $\sigma_j^2 = 0$ ，则将其从特征空间中剔除。

- **重复时间戳处理：** 由于数据采集系统具有高并发写入特性，部分时间点可能存在




图 3-3 数据预处理流程

时间戳重复（Duplicate Timestamp）的情况。为保证时间序列的单调性，本文采用“保留最新”策略，即对于同一时间戳对应的多条记录，仅保留最后写入的一条数据。

• **量纲统一（标准化）**：由于 CPU 使用率（百分比）、网络流量（字节数）、磁盘读写速度（次/秒）等特征在量纲和数值尺度上差异显著，若直接输入模型将导致欧氏距离计算被大数值特征主导。因此，本文采用 Z-score 标准化方法对各维特征进行归一化处理：

$$x'_{i,j} = \frac{x_{i,j} - \mu_j}{\sigma_j} \quad (3-8)$$

其中， $x_{i,j}$  表示第  $i$  个样本在第  $j$  维上的原始取值， $\mu_j$  与  $\sigma_j$  分别表示该维度的均值与标准差。

### 3.4.2 异常值处理

在无监督异常检测任务中，“异常值处理”需要格外谨慎，必须严格区分“业务异常”（模型需要检测的目标）与“系统误差”（由数据采集或记录错误导致的异常）。本文的预处理阶段仅针对违反物理常识的系统误差进行修正，而对所有符合业务逻辑的统计异常予以保留，以避免破坏原始数据中的长尾分布结构。

在 SMD 数据集中，系统误差主要表现为数值越界问题。例如，CPU 利用率或内存占用率在物理意义上不可能超过 100%，网络延迟也不可能为负值。针对上述问题，本文采用边界截断（Clipping）策略进行处理，即为每一维特征设定合理的物理取值范围

$[V_{\min}, V_{\max}]$ ，对观测值  $x_{i,j}$  进行如下修正：

$$x_{i,j} = \begin{cases} V_{\max}, & \text{if } x_{i,j} > V_{\max} \\ V_{\min}, & \text{if } x_{i,j} < V_{\min} \\ x_{i,j}, & \text{otherwise} \end{cases} \quad (3-9)$$

通过上述处理，一方面有效修正了由采集探针异常引入的逻辑错误，另一方面完整保留了服务器高负载等极端但真实的“长尾”状态，为后续基于 IED 的多样性权重计算提供了可靠的数据基础。

### 3.4.3 缺失值处理

在长周期的服务器监控过程中，由于网络丢包或采集代理（Agent）重启，常常会出现数据中断现象。对于时间序列数据而言，若直接剔除含有缺失值的样本，将破坏时间序列的连续性，进而影响滑动窗口的构建与建模效果。

考虑到 SMD 数据集的采样间隔较短（通常为分钟级），系统状态在短时间内具有较强的自相关性。因此，针对不同长度的缺失片段，本文采用分级填充策略进行处理：

- **短时缺失** ( $T_{gap} \leq 3$ )：当连续缺失点数量较少时，认为系统状态未发生显著突变，采用线性插值（Linear Interpolation）进行填充，以保持时间序列变化趋势的连续性：

$$x_t = x_{t-1} + (x_{t+k} - x_{t-1}) \times \frac{1}{k+1} \quad (3-10)$$

其中， $x_{t-1}$  和  $x_{t+k}$  分别表示缺失片段前后最近的有效观测值。

- **长时缺失** ( $T_{gap} > 3$ )：当缺失持续时间较长时，往往意味着系统运行环境已发生明显变化，若继续采用插值方式将引入较大误差。因此，对于该类样本，本文直接丢弃其所在的完整时间窗口及其前后相关窗口，不参与模型训练，以避免模型学习到不真实的时序依赖关系。

### 3.4.4 特征筛选

尽管 SMD 和 PSM 数据集已经提供了结构化的性能指标，但原始特征空间中仍然存在大量冗余信息。在服务器监控场景下，许多指标之间具有较强的物理耦合关系，例如“接收字节数”与“接收包数”通常呈现线性正相关。这类高度相关的特征不仅无法提供额外有效信息，反而会在欧氏距离计算过程中引入“维度偏见”，即同一物理含义被重复计入距离度量，从而影响 IED 的准确性。

为消除多重共线性对距离计算的干扰，本文采用基于 Pearson 相关系数（Pearson Correlation Coefficient）的特征筛选策略，具体过程如下：

- **相关矩阵构建**：计算特征空间中任意两个维度  $i$  与  $j$  之间的线性相关系数  $\rho_{i,j}$ ：

$$\rho_{i,j} = \frac{\text{Cov}(X_i, X_j)}{\sigma_{X_i} \sigma_{X_j}} = \frac{\sum (x_i - \bar{x}_i)(x_j - \bar{x}_j)}{\sqrt{\sum (x_i - \bar{x}_i)^2} \sqrt{\sum (x_j - \bar{x}_j)^2}} \quad (3-11)$$

• **冗余特征剔除策略：**设定相关性阈值  $\tau = 0.95$ 。当  $|\rho_{i,j}| > \tau$  时，认为特征  $X_i$  与  $X_j$  存在高度冗余。在此情况下，考虑到计算效率与信息保留能力，本文保留方差较大的特征（信息量更丰富），并剔除其余冗余维度，从而在保证信息完整性的前提下有效压缩特征空间。

### 3.4.5 特征降维

虽然本文提出的深度神经网络本身具备较强的非线性特征提取能力，但在预处理阶段引入线性特征降维方法，能够有效去除数据中的高斯白噪声，并对输入空间进行正交化处理，从而加速模型的收敛过程。

针对 SMD 数据集特征维度适中（38 维）但噪声较大的特点，本文采用主成分分析（Principal Component Analysis, PCA）进行初步降维处理。PCA 通过正交变换将一组可能存在相关性的变量映射为一组线性不相关的主成分，其核心步骤如下。

• **协方差矩阵分解：**对标准化后的数据矩阵  $X$  计算其协方差矩阵  $\Sigma$ ，并进行特征值分解：

$$\Sigma = \frac{1}{N-1} X^T X = V \Lambda V^T \quad (3-12)$$

其中， $V$  表示特征向量矩阵， $\Lambda$  为由特征值  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$  组成的对角矩阵。

• **累计方差贡献率筛选：**特征值  $\lambda_i$  表示第  $i$  个主成分所包含的信息量。为在降维的同时最大限度保留原始数据的结构特征，本文依据累计方差贡献率（Cumulative Explained Variance Ratio）确定保留的主成分数量  $k$ ：

$$\frac{\sum_{i=1}^k \lambda_i}{\sum_{j=1}^D \lambda_j} \geq \gamma \quad (3-13)$$

实验中设置阈值  $\gamma = 0.98$ ，即保留能够解释 98% 数据方差的主成分。

通过上述处理，仅剔除方差极小、通常对应于随机噪声的维度，在最大程度保留原始信息的同时，显著提升了特征空间的紧凑性与正交性。这为后续的训练以及 IED 多样性距离的稳定计算奠定了高质量的数据基础。

## 3.5 实验结果与分析

在完成针对 SMD 和 PSM 数据集的预处理及特征工程后，本节将对基于实例多样性（IED）加权的超球体学习模型进行系统性的实验评估。实验的核心目标在于回答以下三个关键问题：

• **有效性验证：**IED 加权机制是否能够有效纠正特征中心在长尾分布下的偏移问题，从而在保持较高召回率的同时显著降低误报率？

• **对比优势：**与现有主流异常检测方法（如传统 SVDD、自编码器以及其他生成式模型）相比，所提出的方法在多变量时间序列场景下是否具备更优的综合性能表现？

• **机制解析：**模型中的关键组成模块（如多样性评估机制、加权策略等）分别对最终检测性能产生了怎样的影响？

为回答上述问题，本节首先对实验中采用的评价指标进行定义，随后给出模型在基准数据集上的整体检测性能结果，并通过对比实验与消融实验对模型各组成部分的作用机制进行深入分析与验证。

### 3.5.1 评价指标

由于网络流量异常检测本质上属于高度类别不平衡的二分类问题，其中正常样本占据绝对多数，而异常样本极为稀缺，因此单纯使用准确率（Accuracy）难以客观反映模型真实性能。例如，在异常样本比例仅为 1% 的数据集中，若模型将所有样本均预测为正常，仍可获得 99% 的准确率，但该模型在实际入侵检测场景中显然是不可用的。

基于上述原因，本文选取精确率（Precision）、召回率（Recall）、F1-Score 以及 AUC-ROC 作为核心评价指标。所有指标均基于混淆矩阵（Confusion Matrix）进行计算，其四种基本状态定义如下：

- **真正例（True Positive, TP）：**真实的异常流量被模型正确判定为异常。
- **假正例（False Positive, FP）：**正常业务流量被模型错误识别为异常，即误报。在长尾分布场景下，大量边缘正常样本极易导致 FP 增加，因此降低误报率是本文重点优化目标之一。
- **真负例（True Negative, TN）：**正常业务流量被模型正确判定为正常。
- **假负例（False Negative, FN）：**真实异常流量被模型误判为正常，即漏报，该情况在安全场景中具有较高风险。

在此基础上，各评价指标的定义及其物理意义如下。

**(1) 精确率（Precision）** 精确率衡量模型判定为异常的样本中，真正属于异常的比例，其计算公式为：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (3-14)$$

**本文意义：**精确率反映了模型的抗干扰能力。在本文研究场景中，提高 Precision 表示模型能够有效区分“长尾稀疏正常样本”与“真实异常行为”，从而减少误报率，降低运维人员的告警处理负担。

**(2) 召回率（Recall）** 召回率表示所有真实异常样本中被模型成功检测出的比例，其定义为：

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3-15)$$

**本文意义：**召回率反映系统对异常行为的覆盖能力。在安全检测任务中，高召回率是基本要求，本文旨在在保证召回率不下降的前提下，进一步提升模型的判别精度。

(3) **F1-Score** F1-Score 是 Precision 与 Recall 的调和平均, 用于综合评价模型在不平衡数据集上的整体性能:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3-16)$$

**本文意义:** 由于 Precision 与 Recall 往往存在权衡关系, F1-Score 能够更全面地反映模型在异常检测任务中的综合表现。只有当模型同时兼顾异常覆盖能力与误报控制能力时, 才能取得较高的 F1 值。

(4) **AUC-ROC** ROC 曲线 (Receiver Operating Characteristic Curve) 以假正例率 (False Positive Rate, FPR) 为横轴, 真正例率 (True Positive Rate, TPR) 为纵轴绘制。其曲线下的面积 AUC 定义为:

$$\text{AUC} = \int_0^1 \text{TPR}(t) d(\text{FPR}(t)) \quad (3-17)$$

**本文意义:** 不同于依赖固定阈值的评价指标, AUC 描述了模型在所有可能判别阈值下的整体区分能力。AUC 值越接近 1, 说明模型越能够将异常样本的评分整体排在正常样本之前, 体现了模型对异常程度建模的全局有效性。

### 3.5.2 对比实验

为了全面评估基于实例多样性加权的超球体模型 (IED-Deep SVDD) 在多变量时间序列异常检测中的性能, 本节选取了 5 种不同技术路线的主流基准模型进行对比。实验在 SMD 和 PSM 两个数据集上进行, 重点考察模型在长尾分布数据下的误报控制能力 (Precision) 及综合检测性能 (F1-Score 和 AUC)。

为了保证对比的广泛性, 本文涵盖了从传统统计方法到最新的深度注意力机制模型:

- **OC-SVM (One-Class SVM):** 基于核函数的传统浅层单分类模型, 作为非深度学习方法的性能基准。

- **OmniAnomaly<sup>[36]</sup>:** 基于随机循环神经网络 (Stochastic RNN) 的变分自动编码器, 利用重构概率与隐变量分布来判定异常。

- **USAD (Unsupervised Anomaly Detection)<sup>[37]</sup>:** 结合自动编码器 (AE) 与生成对抗网络 (GAN) 的双阶段训练框架, 在工业界应用广泛。

- **GDN (Graph Deviation Network)<sup>[38]</sup>:** 利用图神经网络 (GNN) 显式建模传感器之间的依赖关系, 通过图注意力的偏差来检测异常。

- **Anomaly Transformer<sup>[39]</sup>:** 利用关联差异 (Association Discrepancy) 机制捕捉长距离时序依赖, 是目前基于 Transformer 架构的 SOTA 模型之一。

- **Ours (IED-Deep SVDD):** 本文提出的基于实例多样性加权的超球体学习方法。

表 3-2 展示了各模型在 SMD 和 PSM 数据集上的详细性能数据。评价指标包括精确率 (Precision)、召回率 (Recall)、F1-Score 以及 AUC-ROC。其中, Precision 反映了对

长尾正常样本的抗干扰能力，AUC-ROC 则反映了模型异常评分的全局排序能力。

表 3-2 不同方法在 SMD 与 PSM 数据集上的性能对比（单位：%）

| 模型                   | SMD (Server Machine Dataset) |              |              |              | PSM (Pooled Server Metrics) |              |              |              |
|----------------------|------------------------------|--------------|--------------|--------------|-----------------------------|--------------|--------------|--------------|
|                      | Precision                    | Recall       | F1           | AUC          | Precision                   | Recall       | F1           | AUC          |
| OC-SVM               | 75.32                        | 81.45        | 78.27        | 79.50        | 71.20                       | 83.15        | 76.71        | 78.40        |
| OmniAnomaly          | 83.45                        | 94.51        | 88.63        | 90.12        | 86.12                       | 92.40        | 89.15        | 91.05        |
| USAD                 | 88.10                        | 95.80        | 91.79        | 93.45        | 89.55                       | 93.82        | 91.63        | 92.88        |
| GDN                  | 90.25                        | 96.10        | 93.08        | 94.80        | 92.30                       | 95.10        | 93.68        | 95.20        |
| Anomaly Transformer  | 92.14                        | <b>96.85</b> | 94.43        | 96.10        | 94.50                       | 96.20        | 95.34        | 96.55        |
| <b>IED-Deep SVDD</b> | <b>93.85</b>                 | 96.60        | <b>95.20</b> | <b>96.85</b> | <b>95.88</b>                | <b>96.55</b> | <b>96.21</b> | <b>97.10</b> |

基于表 3-2 的实验数据，可以从以下三个维度对模型性能进行深入分析：

1. 长尾误报抑制能力 (Precision 显著提升) 本文方法在精确率 (Precision) 指标上展现了稳定的优势。在 SMD 数据集上，本文方法的 Precision 达到 93.85%，相比于 SOTA 模型 Anomaly Transformer (92.14%) 提升了约 1.7%，相比于 USAD (88.10%) 提升了约 5.8%。虽然提升幅度看似温和，但在大规模运维场景下，这意味着每天能减少大量由长尾正常流量引发的无效告警。这证明了 IED 加权机制能有效缓解传统模型对稀疏正常样本的“过度敏感”问题，在不破坏检测边界的前提下，成功覆盖了更多的长尾正常区域。

2. 综合检测性能的平衡性 (F1-Score 优势) 实验结果表明，IED-Deep SVDD 并没有为了追求高 Precision 而严重牺牲召回率。在 SMD 数据集上，虽然 Recall (96.60%) 略微低于 Anomaly Transformer (96.85%)，但凭借 Precision 的优势，最终在 F1-Score 上达到了 95.20%，取得了综合最优的性能。这种“Precision 提升、Recall 持平”的现象是非常理想的，说明模型通过 IED 权重校正，主要剔除的是处于边界模糊地带的“假阳性”样本，而非简单地放宽检测阈值。

3. 与时序注意力模型的对比与鲁棒性 (AUC-ROC) Anomaly Transformer 凭借强大的时序关联建模能力，在 Recall 指标上表现极其强劲。然而，其 Precision 相对受到长尾分布的影响。本文方法在 PSM 数据集上的 AUC 达到 97.10%，略优于 Anomaly Transformer 的 96.55%。这表明，虽然本文采用的是非序列的超球体聚类框架，但通过引入多样性加权，模型输出的异常得分 (Anomaly Score) 在全局分布上具有更好的区分度，能够更鲁棒地将正常长尾样本与真实攻击样本分离开来。

### 3.5.3 消融实验

为了深入验证本文提出的实例多样性加权 (IED-Weighted) 机制及中心校正 (Center Rectification) 策略在长尾分布处理中的具体贡献，本节在 SMD 数据集上设计了消融实验。通过逐步移除模型中的关键组件，构建不同变体模型进行对比分析，以量化各模块

对最终异常检测性能的影响。

实验设置与变体定义，为保证对比的公平性并严格控制变量，本文构建了如下三种模型变体：**Base Model (Vanilla Deep SVDD)**：作为实验的基准下界 (Baseline)，该模型移除了多样性加权模块（即设所有样本权重  $w_i = 1$ ），同时不采用动态特征中心更新策略。其本质等价于 Ruff 等人提出的原始 Deep SVDD 模型<sup>[40]</sup>，用于评估在未显式处理长尾分布情况下的基础性能。

**Model w/o EMA (仅加权，无动态中心)**：该模型保留 IED 多样性加权模块，根据样本稀疏度为损失函数分配不同权重，但在训练过程中移除公式 3-7 所定义的 EMA 中心更新策略，使特征中心  $c$  在整个训练阶段保持固定。该变体旨在验证：在不调整球心位置的前提下，仅依靠损失加权是否足以缓解长尾问题。

**Ours (Full Model)**：本文提出的完整模型，同时引入 IED 多样性加权损失函数与基于权重的 EMA 特征中心动态更新策略。

消融实验在 SMD 数据集上的详细性能对比如表 3-3 所示。

表 3-3 消融实验：不同模块组合对模型性能的影响 (SMD 数据集)

| 模型变体 (Variant)     | 组件配置 (Components) |            | 性能指标 (%)     |              |              |              |
|--------------------|-------------------|------------|--------------|--------------|--------------|--------------|
|                    | IED Weighting     | EMA Update | Precision    | Recall       | F1-Score     | AUC          |
| Base Model         | ×                 | ×          | 86.42        | 94.10        | 90.10        | 91.50        |
| Model w/o EMA      | ✓                 | ×          | 92.15        | 95.05        | 93.58        | 95.20        |
| <b>Ours (Full)</b> | ✓                 | ✓          | <b>93.85</b> | <b>96.60</b> | <b>95.20</b> | <b>96.85</b> |

基于表 3-3 中的实验结果，可以从以下三个方面对模型内部机制进行分析。

IED 加权机制是抑制长尾误报的核心因素，通过对比 Base Model 与 Model w/o EMA 可以发现，仅引入 IED 多样性加权机制后，模型的 Precision 从 86.42% 提升至 92.15%，提升幅度接近 6%。其原因在于，Base Model 的优化过程完全由高频样本主导，为了最小化整体损失，模型倾向于收缩超球体边界以贴合高密度区域，导致大量位于稀疏区域的正常长尾样本被排除在球体之外，从而产生较高的误报率。IED 加权机制通过为稀疏样本赋予更大的梯度权重，迫使模型在训练过程中兼顾这些边缘样本，有效扩展了决策边界，显著降低了虚警。

EMA 中心更新带来性能的进一步提升，进一步对比 Model w/o EMA 与 Ours (Full) 可以发现，在引入基于权重的 EMA 特征中心更新策略后，模型的 F1-Score 进一步提升约 1.6%，同时 Recall 也从 95.05% 提升至 96.60%。

这是因为，仅依靠损失加权虽然能够扩大超球体边界，但若特征中心  $c$  固定不变，球体的几何位置仍可能无法充分适配数据在特征流形上的真实分布。EMA 策略允许特征中心在训练过程中依据加权后的样本分布进行平滑调整，实现中心校正 (Center Rectification)，使超球体逐步移动至覆盖所有正常模式 (包括长尾模式) 的最优位置，从而在保持高 Precision 的同时进一步提升 Recall，实现整体性能的协同优化。

特征空间分布的几何解释，为进一步验证上述量化分析，本文对不同模型的特征空间进行了 t-SNE 降维可视化（如图 3-4 所示）。在 Base Model 的特征空间中，正常样本呈现出“中心致密、边缘破碎”的分布形态，大量长尾样本散落于类簇外围，并与异常样本发生严重混叠。




图 3-4 数据集特征空间 t-SNE 可视化对比

相比之下，在完整模型中，由于 IED 加权与中心校正机制的联合约束，正常样本在特征空间中形成了更加紧凑且连贯的球状结构，长尾样本被有效拉回至正常类簇内部，使正常样本与异常样本之间形成了更清晰的间隔区域（Margin）。这一几何结构上的改善，从直观角度解释了模型在 Precision 与 AUC 指标上的显著提升。

### 3.6 本章小结

针对工业互联网及企业网络流量中普遍存在的长尾分布（Long-tailed Distribution）特性，以及由此引发的传统单分类模型中特征中心偏移与高误报率问题，本文提出了一种基于实例多样性加权的无监督超球体学习方法（IED-Deep SVDD）。

本章的主要研究工作与贡献总结如下：

(1) **构建了无监督的实例多样性度量体系。**引入实例欧氏距离（Instance Euclidean Distance, IED）作为衡量样本在特征空间中局部稀疏性的量化指标，在无标签条件下有效区分了高频“头部”流量与稀疏“尾部”正常流量，为非均衡分布场景下的模型优化提供了可靠的度量依据。

(2) **提出了多样性感知加权与中心动态校正机制。**设计了基于 IED 的多样性感知加权损失函数，通过非线性映射为长尾样本赋予更高的梯度权重，迫使超球体边界向外

自适应扩张以覆盖稀疏的正常区域。同时，引入基于权重的指数滑动平均（Exponential Moving Average, EMA）策略对特征中心进行动态更新，从几何层面缓解了模型训练过程易被高频样本主导、导致决策边界过度收缩的问题。

(3) **验证了模型在抑制长尾误报方面的优越性。**在 SMD 与 PSM 两个公开数据集上的对比实验结果表明，所提出的方法在综合性能指标（F1-Score 与 AUC）上均优于 Anomaly Transformer、MADCluster 等主流异常检测模型，且在 **精确率（Precision）** 指标上取得了显著提升，充分证明了该方法能够有效降低由稀疏正常模式引发的虚假告警。进一步的消融实验与特征空间可视化结果揭示了 IED 加权机制在重构紧凑正常类簇、形成清晰类别隔离带方面的关键作用。

综上所述，本章工作针对复杂长尾分布条件下的无监督异常检测问题给出了有效解决方案，显著提升了模型对稀有但合法正常行为的包容能力，为后续构建高鲁棒性的网络流量异常检测系统奠定了坚实的算法基础。

## 第4章 面向未知攻击的多模式无监督异常流量检测方法

### 4.1 引言

在前文对网络异常流量检测方法的分析基础上可以发现，现有基于聚类的无监督异常检测方法多采用单一聚类中心对正常行为进行建模，难以充分刻画网络流量中正常行为模式多样、分布复杂的实际特征。此外，在真实网络环境中，异常流量往往呈现出类型未知、标签稀缺甚至完全缺失的特点，传统依赖监督信息的方法在此类场景下适用性有限。

针对上述问题，本文以未知攻击场景下的网络异常流量检测为研究背景，提出了一种面向未知攻击场景的网络异常流量多模式无监督聚类检测框架。该框架在保持无监督学习特性的同时，通过多模式聚类建模网络流量中正常行为的潜在分布结构，使模型能够同时刻画不同类型正常流量在特征空间中的表现形式，从而提升对复杂网络流量环境的适应能力与异常检测的鲁棒性。

### 4.2 模型设计

#### 4.2.1 多模式无监督聚类建模思想

在无监督异常检测任务中，模型的核心目标是在缺乏异常标签的条件下，对网络流量中正常行为的分布结构进行有效建模，并据此识别偏离正常模式的异常样本。针对网络正常流量在特征空间中呈现多样化分布的特点，本文引入多模式无监督聚类建模思想，以多个潜在正常行为模式共同刻画正常流量的整体分布。

(1) 样本空间与多模式建模假设

设网络流量样本集合表示为

$$\mathcal{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}, \quad \mathbf{x}_i \in \mathbb{R}^d \quad (4-1)$$

其中， $\mathbf{x}_i$  表示第  $i$  个网络流量样本在  $d$  维特征空间中的向量表示。在无监督学习设定下，样本集合  $\mathcal{X}$  不包含任何异常标签信息。

本文假设：正常网络流量在特征空间中由多个潜在的正常行为模式构成，而非围绕单一中心分布。因此，采用多模式聚类结构对正常流量进行建模更符合真实网络环境下流量分布的特性。

(2) 多模式聚类结构定义

为刻画正常流量的多样化分布，定义正常行为模式集合为

$$\mathcal{E} = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_M\}, \quad \mathbf{e}_m \in \mathbb{R}^d \quad (4-2)$$

其中,  $\mathbf{e}_m$  表示第  $m$  个正常行为模式对应的聚类中心,  $M$  为正常行为模式的数量。

多模式聚类结构通过多个聚类中心共同描述正常样本在特征空间中的潜在分布, 使不同类型的正常流量能够分别围绕其对应的模式中心聚集, 从而形成多个相对独立的正常模式区域。

### (3) 样本与多模式的距离建模

在多模式无监督聚类框架下, 样本  $\mathbf{x}_i$  与所有模式中心之间均存在关联关系。本文通过样本与各模式中心之间的距离来刻画这种关联性, 其数学形式定义为

$$d_{i,m} = \|\mathbf{x}_i - \mathbf{e}_m\|_2, \quad m = 1, 2, \dots, M \quad (4-3)$$

由此, 样本  $\mathbf{x}_i$  可对应一个距离向量

$$\mathbf{d}_i = [d_{i,1}, d_{i,2}, \dots, d_{i,M}] \quad (4-4)$$

该向量刻画了样本在特征空间中相对于多种正常行为模式的位置关系。

### (4) 多模式建模的判别意义

在多模式聚类建模框架下, 正常样本通常满足如下特性:

$$\exists m \in \{1, 2, \dots, M\}, \text{ s.t. } d_{i,m} \leq \delta \quad (4-5)$$

即正常样本至少与某一正常模式中心保持较小距离, 其中  $\delta$  为距离阈值。相反, 异常样本往往同时远离所有模式中心, 其距离向量  $\mathbf{d}_i$  在各维度上均呈现较大取值。这一差异为后续异常得分计算与判别机制提供了明确的建模依据。

为更直观地说明多模式无监督聚类建模思想, 图4-1给出了该方法在二维特征空间中的示意图。如图所示, 蓝色圆点表示模型学习得到的多个正常行为模式聚类中心:




图 4-1 无监督多模式聚类方法示意图

$$\mathcal{E} = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_M\} \quad (4-6)$$

黑色“+”号表示正常网络流量样本，红色圆点表示异常流量样本。

在多模式聚类建模框架下，不同类型的正常流量样本并非围绕单一中心分布，而是分别聚集在多个聚类中心附近，形成多个相对独立但可能部分重叠的正常模式区域。图中以半透明椭圆区域示意各正常模式在特征空间中的覆盖范围，体现了多模式聚类对正常流量多样化分布的刻画能力。

对于任一网络流量样本，其在特征空间中均可计算其与各聚类中心之间的距离关系。正常样本通常至少与某一聚类中心保持较小距离，因此能够被有效覆盖于某一正常模式区域内；而异常样本则往往同时远离所有聚类中心，分布于多个正常模式覆盖区域之外，从而在距离空间中呈现出显著差异。

通过引入多模式无监督聚类建模思想，本文以多个潜在正常行为模式对网络流量进行结构化建模，有效缓解了单一聚类中心在复杂流量场景下的建模不足问题，并为后续基于多模式聚类的异常判别机制奠定了数学基础。

#### 4.2.2 多模式无监督聚类建模方法

基于多模式无监督聚类建模思想，本文进一步构建了一种面向网络异常流量的多模式无监督聚类建模方法，其整体模型架构如图4-2所示。该方法围绕“多模式正常行为建模”这一核心目标展开，通过对样本与多个聚类中心之间关系的系统建模，实现对复杂网络流量分布结构的精细刻画。




图 4-2 无监督多模式聚类模型架构图

从整体结构上看，该模型主要由特征输入层、多模式聚类中心集合、样本—模式关联建模模块以及聚类中心更新机制组成，各模块之间形成闭环交互，共同完成多模式无监督聚类建模过程。

在输入端，网络流量样本经过特征构建后被映射至统一的特征空间，形成样本表示集合

$$\mathcal{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}, \quad \mathbf{x}_i \in \mathbb{R}^d \quad (4-7)$$

该特征空间用于统一描述不同网络流量样本在统计特性与行为特性上的差异，为后续聚类建模提供基础表示。

在特征空间中，模型引入由  $M$  个聚类中心构成的多模式结构

$$\mathcal{E} = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_M\} \quad (4-8)$$

用于刻画网络正常流量中潜在的多种行为模式。与传统单中心建模方法不同，该结构允许多个聚类中心同时存在，并分别对应不同类型的正常流量行为。图中以多个聚类中心及其覆盖区域直观展示了多模式结构在特征空间中的分布形态。

在样本一模式关联建模阶段，模型对每个样本与所有聚类中心之间的关系进行显式建模。具体而言，对于任一样本  $\mathbf{x}_i$ ，模型计算其与第  $m$  个聚类中心之间的距离：

$$d_{i,m} = \|\mathbf{x}_i - \mathbf{e}_m\|_2 \quad (4-9)$$

由此得到样本  $\mathbf{x}_i$  在多模式结构下的距离向量

$$\mathbf{d}_i = [d_{i,1}, d_{i,2}, \dots, d_{i,M}] \quad (4-10)$$

该距离向量在模型架构中起到核心作用：一方面用于刻画样本在特征空间中相对于各正常行为模式的位置关系；另一方面为样本与多模式之间的软关联建模提供依据。通过距离映射机制，模型将距离信息转换为样本对各聚类中心的关联权重，从而避免硬分配带来的模式割裂问题，使样本能够同时受到多个正常模式的约束。

在聚类中心学习与更新阶段，模型依据样本一模式关联结果对聚类中心进行迭代更新。每个聚类中心通过聚合与其关联度较高的样本进行调整，其更新形式可表示为：

$$\mathbf{e}_m \leftarrow \frac{\sum_{i=1}^N \alpha_{i,m} \mathbf{x}_i}{\sum_{i=1}^N \alpha_{i,m}} \quad (4-11)$$

其中， $\alpha_{i,m}$  表示样本  $\mathbf{x}_i$  对第  $m$  个聚类中心的贡献权重。该更新机制使聚类中心能够逐步向其所代表的正常行为模式的高密度区域收敛，并在训练过程中不断自适应调整其位置。

随着聚类中心的反复更新，多模式结构在特征空间中逐渐稳定，各模式的覆盖范围与相对位置关系能够较为准确地反映网络正常流量的真实分布形态。正常样本通常在至少一个聚类中心附近具有较小距离，而异常样本则往往同时远离所有聚类中心，分布于多模式覆盖区域之外。

通过上述多模式无监督聚类建模方法，模型在无须异常标签的条件下实现了对正常流量多样化分布结构的系统刻画，为后续基于多模式距离关系的异常得分计算与检测判别提供了清晰、稳定且具有判别力的结构基础。

### 4.2.3 异常得分计算机制和损失函数

在完成多模式无监督聚类结构的学习后，模型已在特征空间中形成对网络正常流量分布的多中心刻画。在此基础上，本文进一步构建基于多模式距离结构的异常得分计算机制，并设计与之相匹配的无监督损失函数，实现对异常流量的有效判别。

#### (1) 基于多模式最近匹配原则的异常得分机制

在多模式无监督聚类建模框架下，正常网络流量样本通常能够与至少一种正常行为模式保持较高的一致性，而异常样本则往往同时偏离所有正常模式。基于这一判别特性，本文采用最近匹配原则构建异常得分函数，其定义为：

$$s_i = \min_{m \in \{1, 2, \dots, M\}} d_{i,m} \quad (4-12)$$

其中， $s_i$  表示样本  $\mathbf{x}_i$  的异常得分， $M$  为正常行为模式（聚类中心）的数量， $d_{i,m}$  表示样本  $\mathbf{x}_i$  与第  $m$  个正常行为模式中心之间的距离。该异常得分刻画了样本与其最接近正常行为模式之间的偏离程度。

当样本能够被某一正常模式有效覆盖时，其异常得分较低；而当样本无法与任何正常模式形成良好匹配时，其异常得分将显著增大。相较于基于单一中心的距离判别方式，该机制能够充分利用多模式结构信息，有效降低复杂流量场景下对边缘正常样本的误判风险。

#### (2) 多模式加权一致性的异常得分扩展形式

考虑到部分网络流量样本可能同时与多个正常行为模式存在关联，单一最近模式距离在某些情况下可能不足以全面反映样本的整体偏离程度。为此，本文进一步引入基于模式关联权重的异常得分扩展形式：

$$s_i = \sum_{m=1}^M \alpha_{i,m} d_{i,m} \quad (4-13)$$

其中， $\alpha_{i,m}$  表示样本  $\mathbf{x}_i$  对第  $m$  个正常行为模式的关联权重，用于刻画样本在多模式结构下对不同模式的相对一致性程度。该异常得分通过综合考虑样本在各正常行为模式下的偏离情况，使判别结果不仅依赖于单一模式，而是反映样本在整体正常分布结构中的相对位置。

当样本在所有模式下均表现出较大距离时，其加权异常得分将显著增大，从而更有利于识别分布型或复合型异常行为。

#### (3) 面向多模式聚类建模的无监督损失函数

在无监督异常检测场景下，模型训练无法直接利用异常标签信息，因此本文从多模式聚类建模的角度出发，构建基于样本一模式一致性的无监督优化目标。整体损失函数定义为：

$$\mathcal{L} = \sum_{i=1}^N \sum_{m=1}^M \alpha_{i,m} d_{i,m}^2 \quad (4-14)$$

其中,  $N$  表示训练样本总数,  $\alpha_{i,m}$  与  $d_{i,m}$  分别表示样本  $\mathbf{x}_i$  与第  $m$  个正常行为模式之间的关联权重及其距离。该损失函数通过对样本在多模式结构下的加权平方距离进行联合最小化, 引导模型在特征空间中形成紧凑且具有区分性的多中心分布结构。

#### (4) 异常得分机制与损失函数的一致性分析

上述异常得分计算机制与无监督损失函数在建模目标上保持高度一致。损失函数侧重于在训练阶段学习能够覆盖正常行为分布的多模式结构, 而异常得分机制则在推理阶段利用该结构评估样本相对于正常分布的偏离程度。异常样本由于难以与任何正常模式形成稳定一致性, 在训练过程中无法获得有效的结构支持, 最终在异常得分空间中表现为显著偏高的取值。

因此, 本文所设计的异常得分计算机制与损失函数共同构成一个统一的无监督异常检测框架, 能够在未知攻击场景下实现对网络异常流量的稳定识别。

算法 2 展示了多模式无监督异常流量检测的训练过程。

---

#### Algorithm 2: 面向未知攻击的多模式无监督异常流量检测

---

**Input:** 网络流量样本集合  $\mathcal{X}$ ; 聚类中心数量  $M$ ; 最大训练轮数  $T$

**Output:** 聚类中心集合  $\mathcal{E}$ ; 异常得分  $\{s_i\}$

初始化聚类中心  $\mathcal{E}^{(0)}$ ;

**for**  $t = 0$  **to**  $T - 1$  **do**

**foreach** 样本  $\mathbf{x}_i \in \mathcal{X}$  **do**

        计算  $d_{i,m}^{(t)}$  并得到  $\alpha_{i,m}^{(t)}$ ;

**for**  $m = 1$  **to**  $M$  **do**

$\mathbf{e}_m^{(t+1)} \leftarrow \frac{\sum_i \alpha_{i,m}^{(t)} \mathbf{x}_i}{\sum_i \alpha_{i,m}^{(t)}}$ ;

**foreach** 样本  $\mathbf{x}_i \in \mathcal{X}$  **do**

$s_i = \min_m \|\mathbf{x}_i - \mathbf{e}_m\|_2$ ;

---

## 4.3 实验数据集与环境

### 4.3.1 实验数据集介绍

本文实验主要采用 SMD (Server Machine Dataset)、PSM (Pooled Server Metrics)、UNSW-NB15 以及 CIC-IDS2017 四个数据集, 对所提出的网络流量异常检测方法进行验证。上述数据集分别来源于真实服务器运行环境和网络通信场景, 涵盖网络系统运行异常与网络攻击流量异常两类典型应用, 为模型性能评估提供了多样化的数据支撑。

#### 1. SMD (Server Machine Dataset) 数据集

SMD (Server Machine Dataset) 数据集来源于真实服务器集群的长期运行监控系统, 是多变量时间序列异常检测领域中广泛使用的基准数据集之一。该数据集记录了服务器在连续运行过程中采集的多维监控指标, 包括 CPU 使用率、内存占用、磁盘 I/O 以及网

络通信相关负载信息，能够全面反映服务器及其网络环境的运行状态。

SMD 数据集包含 38 个监控维度，异常样本主要由服务器硬件故障、资源瓶颈、网络异常以及系统性能退化等因素引起。其异常模式复杂、噪声水平较高，能够较好模拟真实网络运行环境中系统状态与流量行为的动态变化，适用于评估异常检测模型在复杂网络系统场景下的检测能力与鲁棒性。

## 2. PSM (Pooled Server Metrics) 数据集

PSM (Pooled Server Metrics) 数据集采集自大型互联网企业的真实生产环境服务器集群，记录了多台服务器节点的聚合运行监控指标。该数据集包含约 25 个关键监控维度，涵盖系统负载、资源使用情况以及网络通信状态等信息，能够反映实际网络服务环境中的整体运行特征。

与 SMD 数据集相比，PSM 数据集的异常比例相对较高，异常类型更加多样，既包括突发性的网络运行异常事件，也包含持续性的系统性能退化问题。该数据集在高异常密度场景下对模型的稳定性和泛化能力提出了更高要求，常用于验证异常检测模型在真实复杂网络运行环境中的应用效果。

## 3. UNSW-NB15 数据集

UNSW-NB15 数据集由澳大利亚新南威尔士大学网络安全与隐私研究小组构建，是一个面向现代网络通信场景的综合性网络流量数据集。该数据集通过搭建真实网络仿真环境，采集正常网络通信流量与多种异常网络行为，并利用多种流量分析工具对网络连接进行特征提取。

UNSW-NB15 数据集共包含 49 个网络流量特征维度，涵盖连接统计特征、内容特征及时间特征，能够较为全面地描述网络流量的行为模式。该数据集在网络流量异常检测与入侵检测研究中被广泛采用，适合用于评估模型在复杂网络通信环境下对异常流量行为的识别能力。

## 4. CIC-IDS2017 数据集

CIC-IDS2017 数据集由加拿大网络安全研究所 (CIC) 设计并发布，是一个高质量的网络流量异常检测基准数据集。该数据集基于接近真实网络环境的实验场景构建，系统性地采集了正常网络通信流量以及多种异常网络行为对应的流量数据。

CIC-IDS2017 数据集在数据真实性、场景多样性和特征完整性方面具有显著优势，能够反映真实网络环境中流量行为的复杂变化规律。该数据集被广泛应用于网络流量异常检测与入侵检测研究中，适用于验证异常检测模型在多种网络异常场景下的检测性能与泛化能力。

### 4.3.2 实验环境与参数设置

为系统验证本文提出的面向未知攻击场景的多模式无监督聚类异常检测方法的有效性与稳定性，本文在统一且较为先进的软硬件实验环境下完成模型训练、推理与性能

评估。实验运行平台的具体配置如表 4-1 所示。

表 4-1 实验环境与运行平台配置

| 实验环境    | 配置说明                             |
|---------|----------------------------------|
| 操作系统    | Ubuntu 22.04 LTS（64 位）           |
| 编程语言    | Python 3.9                       |
| 集成开发环境  | Trae 3.3.22                      |
| 深度学习框架  | PyTorch 1.13.1                   |
| CUDA 版本 | CUDA 12.1                        |
| CPU     | Intel(R) Core(TM) i7-12700K      |
| GPU     | NVIDIA GeForce RTX 3080（10GB 显存） |
| 内存      | 32GB DDR4                        |

在软件环境方面，实验采用 Ubuntu 22.04 LTS 操作系统，并基于 Python 3.9 语言进行算法实现。模型构建与训练依托 PyTorch 1.13.1 深度学习框架完成，该框架在张量运算效率、自动求导机制以及 GPU 并行计算支持方面具有良好性能，能够满足多模式聚类中心联合学习与动态更新的实验需求。CUDA 11.7 被用于加速模型在大规模网络流量数据上的训练过程，以提高整体计算效率。

在硬件环境方面，实验平台配备 Intel(R) Core(TM) i7-12700K 处理器和 NVIDIA GeForce RTX 3080 显卡，并配置 32GB 系统内存。该硬件条件能够支持多模式聚类结构中多中心距离计算、样本一模式关联建模以及异常得分推理等计算密集型操作，确保实验过程的稳定性与可重复性。

在参数设置方面，多模式聚类模型中聚类中心数量  $M$  根据不同数据集的流量复杂度进行设置，其余关键超参数在无监督设定下通过经验调节与验证集分析确定。为保证实验结果的公平性与可对比性，本文所有对比实验均在相同软硬件环境与一致的数据预处理流程下完成。

## 4.4 实验与分析

### 4.4.1 评价指标

### 4.4.2 实验结果

### 4.4.3 对比实验

### 4.4.4 消融实验

## 4.5 本章小结

在本章节中，首先介绍了整个联邦学习的训练流程。首先初始化模型参数，然后通过多轮训练不断更新积液检测模型与局部化中心模型，之后从训练过程中挑选出表现最佳的局部化中心模型。最后，通过微调进一步提升模型的性能，确保模型在特定任务上的优化效果。

接着，介绍了动态双向权重调节机制，该机制包括两个主要部分：第一部分是中心化加权聚合，根据积液检测模型与上一轮局部化中心模型参数之间的距离来确定权重值。第二部分是知识迁移权重调节，根据每个积液检测模型对局部化中心模型的贡献率（权重值）来调节局部化中心模型的知识迁移比例。

为了验证该框架的有效性，我们进行了一系列实验。在多个数据集上的实验结果表明，框架在提高平均 F1 得分方面表现优异。此外，我们还进一步研究了模型微调、动态双向权重调节机制、温度系数和知识迁移权重函数对模型性能的影响，并找到了能够显著提升效果的最佳条件。

## 第 5 章 针对投毒攻击的页岩气井积液检测联邦防御算法

在页岩气井积液检测的联邦学习场景中，隐私保护和模型安全性是亟待解决的关键问题。页岩气井的地质环境复杂多样，数据分布差异显著，这使得联邦学习在提升积液检测模型性能的同时，也面临着投毒攻击等安全威胁。为此，本研究针对投毒攻击提出了一种综合性的页岩气井积液检测联邦防御算法，旨在构建一个更加安全、高效的联邦学习框架，以应对实际应用中的隐私保护和攻击防御挑战。

首先，为确保数据隐私，本研究将生成对抗网络与差分隐私相结合，设计了鉴别器损失和噪声尺度正则化损失两个损失函数。鉴别器损失促使生成器生成的数据尽量接近真实数据，以减少隐私保护措施对积液检测模型性能的负面影响；而噪声尺度正则化损失则确保生成数据中包含足够的噪声以保护隐私。通过这两个损失函数的对抗性训练，寻找隐私保护与积液检测模型性能之间的最佳平衡点。

其次，针对数据投毒攻击，本研究在知识迁移权重调节算法的基础上，结合基于注意力蒸馏的防御算法，形成了一种基于注意力蒸馏的知识迁移算法。该方法通过注意力蒸馏过程中利用少量的干净数据进行微调来消除后门触发器，有效提高了协同优化过程中模型在面对数据投毒攻击时的鲁棒性和安全性。

最后，针对模型投毒攻击，本研究将拜占庭弹性聚合与中心化加权聚合相结合，形成了一种中心化弹性聚合算法。该算利用中心化加权聚合来避免正常参与方使用中毒的局部化中心模型，同时利用弹性机制识别并抑制异常的积液检测模型更新，从而确保协同训练后的积液检测模型始终处于安全状态。通过这种多层次的防御策略，为页岩气井积液检测联邦学习模型提供了一道坚固的安全防线。

### 5.1 隐私保护

在隐私保护阶段，我们提出了一种结合差分隐私和生成对抗网络的综合方法，旨在为页岩气井积液检测中的联邦学习提供强大的隐私保护机制。差分隐私通过在数据中添加噪声来保护隐私，但传统方法可能对模型性能产生负面影响。为此，我们引入生成对抗网络，利用其生成能力在保护隐私的同时，生成高质量的合成数据以维持模型的检测精度。通过精心设计的鉴别器损失和噪声尺度正则化损失，我们实现了隐私保护与模型性能之间的最佳平衡。

#### 5.1.1 差分隐私

在积液检查模型参数加密过程中，敏感度本质上是指本地训练数据对局部模型参数的影响。敏感度计算的核心是衡量单个数据点对查询结果的影响，可以通过观察训练前后模型参数的变化来量化。具体来讲，对于第  $t$  轮局部模型参数  $\theta^t$ ，其敏感度可以通过

如下公式来定义：

$$\Delta f = \max_x \|\theta^t - \theta^{t-1}\|_2 \quad (5-1)$$

其中， $\|\cdot\|$  是 L2 范数。 $\theta^{t-1}$  是上一轮训练后的积液检测模型参数。如果敏感度较大，意味着数据集对模型的影响很大。为了保持隐私，在这种情况下需要加入更多的噪声来掩盖影响。

随后，计算出决定噪声强度的尺度参数  $b$ ，它由敏感度  $\Delta f$  和隐私预算  $\epsilon$  决定：

$$b = \frac{\Delta f}{\epsilon} \quad (5-2)$$

其中，隐私预算  $\epsilon$  为控制差分隐私强度的超参数，较小的  $\epsilon$  提供 stronger 的隐私保护，但也会引入更多的噪声。

为了从给定的概率分布中采样噪声，首先要确定概率分布的概率密度函数。然后计算概率密度函数的积分，即累积分布函数。累积分布函数表示随机变量  $X$  取值小于或等于某个值的概率，即：

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt \quad (5-3)$$

在本研究中，我们采用了拉普拉斯分布，累积分布函数表示从负无穷到噪声  $x$  之间的面积或概率。

$$F(x|\mu, b) = \begin{cases} \frac{1}{2}\exp(\frac{x-\mu}{b}) & \text{if } x \geq \mu \\ 1 - \frac{1}{2}\exp(\frac{-x+\mu}{b}) & \text{if } x < \mu \end{cases} \quad (5-4)$$

其中， $x$  是噪声的随机变量。 $\mu$  是分布的均值，在差分隐私中通常取 0。 $b$  是尺度参数。

我们采用了逆变换抽样法来生成噪声。具体来说，先从均匀分布  $U(0, 1)$  中采样一个在  $[0, 1]$  区间随机数  $u$ ，然后将这个均匀分布的随机数  $u$  输入到分布的逆累积分布函数中，得到符合目标分布的噪声  $x$ 。拉普拉斯分布的逆累积分布函数是通过解以下方程得到的：

$$u = F(x|\mu, b) \quad (5-5)$$

通过变形得到  $x$ ：

$$x = \mu - b \cdot \text{sign}(u - 0.5) \cdot \ln(1 - 2|u - 0.5|) \quad (5-6)$$

$$\text{sign}(x) = \begin{cases} 1 & \text{if } x > 0 \\ 0 & \text{if } x = 0 \\ -1 & \text{if } x < 0 \end{cases} \quad (5-7)$$

其中， $\mu$  是分布的均值，通常为 0。 $\ln$  是自然对数，确保噪声值的概率在靠近零时较高，远离零时较低。 $\text{sign}(u - 0.5)$  确保噪声的正负对称分布。生成的噪声  $x$  被添加到积液检测模型的参数  $\theta$  中，以确保隐私保护。对于每个积液检测模型参数  $\theta$ ，添加噪声后的带噪声参数  $\hat{\theta}$  为：

$$\hat{\theta} = \theta + x \quad (5-8)$$

### 5.1.2 生成对抗网络

生成对抗网络的目的是为了训练一个生成器，使得差分隐私中加入的噪声尽量减少对积液检测模型性能的影响。首先，我们选择积液检测模型训练过程中的某一阶段的参数作为训练鉴别器的正负样本基础。具体来说，假设模型总共训练了  $T$  轮，并在第  $m$  轮时已经收敛，第  $n(n > m)$  到  $T$  轮训练中的模型参数（真实数据）作为正样本，共计  $N$  轮，记为  $\theta = \{\theta_i\}_{i=1}^N$ 。加噪后的模型参数（加噪数据）作为负样本，记为  $\hat{\theta} = \{\hat{\theta}_i\}_{i=1}^N$ 。鉴别器是一个 MLP 网络，其目标是区分正样本和负样本，判断模型参数真实数据还是加噪数据。鉴别器在更新过程中的梯度变化可表示为：

$$\nabla_{\theta_D} \frac{1}{2N} \sum_{i=1}^N [\log D(\theta_i) + \log(1 - D(\hat{\theta}_i))] \quad (5-9)$$

其中， $\nabla_{\theta_D}$  为鉴别器模型参数的梯度， $D(\theta_i)$  和  $D(\hat{\theta}_i)$  为鉴别器对真实数据和加噪数据的判断结果，理想状态下为 1 和 0。在完成鉴别器的训练后，我们将鉴别器的权重固定下来，并使用这个固定的鉴别器来训练生成器。固定鉴别器的好处是，它能够在生成器训练过程中提供稳定的反馈，指导生成器生成更真实的数据。

生成器的输入是加噪数据  $\hat{\theta}$ ，目标是让生成数据  $G(\hat{\theta})$  尽可能接近真实数据  $\theta$ ，但同时保留足够的噪声干扰，以确保隐私保护的同时避免模型性能的下降。为了实现该目的，生成器的损失函数由鉴别器损失和噪声尺度正则化损失两部分构成。从鉴别器损失来看，生成器希望生成的模型参数无法被鉴别器区分，即生成数据应该让鉴别器误判为真实数据。该损失帮助生成器生成与真实数据分布相似的数据，在更新过程中的梯度变化可表示为：

$$\nabla_{\theta_G} \frac{1}{N} \sum_{i=1}^N \log(D(G(\hat{\theta}_i))) \quad (5-10)$$

其中， $\nabla_{\theta_G}$  为生成器模型参数的梯度， $D(G(\hat{\theta}_i))$  为鉴别器对生成数据的判断结果，理想状态下为 1。

从噪声尺度正则化损失来看，生成器希望生成的数据保持适当的噪声水平，以防过度去噪，从而影响参数的隐私性。噪声尺度正则化损失在更新过程中的梯度变化可表示为：

$$-\nabla_{\theta_G} \frac{1}{N} \sum_{i=1}^N e^{-(\Delta G - \Delta \hat{\theta}_i)} \|\Delta G - \Delta \hat{\theta}_i\|_2 \quad (5-11)$$

$$\Delta \hat{\theta}_i = \|\hat{\theta}_i - \theta_i\|_2 \quad (5-12)$$

$$\Delta G(\hat{\theta}_i) = \|G(\hat{\theta}_i) - \theta_i\|_2 \quad (5-13)$$

其中,  $\theta_i$  为真实数据。  $\hat{\theta}_i$  为加噪数据。  $G(\hat{\theta}_i)$  为生成数据。当  $G(\hat{\theta}_i)$  接近或大于  $\hat{\theta}_i$  时, 梯度变化接近于 0, 而当  $G(\hat{\theta}_i)$  小于  $\hat{\theta}_i$  且差距较大时, 梯度会明显增大。

鉴别器损失和噪声尺度正则化损失之间存在一定的对抗关系。前者促使生成器尽量减少生成数据与真实数据之间的差异, 而后者则要求生成器保持生成数据的噪声强度, 以保护隐私。基于上述公式, 该生成器的损失函数可以进一步描述为:

$$\mathcal{L}_G = -\mathbb{E}_{\hat{\theta}_i \sim p_{\text{data}}(\hat{\theta}_i)} [\log(D(G(\hat{\theta}_i)))] + \lambda \mathbb{E}_{\hat{\theta}_i \sim p_{\text{data}}(\hat{\theta}_i)} \left[ e^{-(\Delta G - \Delta \hat{\theta}_i)} \|\Delta G - \Delta \hat{\theta}_i\|_2 \right] \quad (5-14)$$

其中,  $\lambda$  是一个超参数, 用于平衡两个损失函数对最终损失的贡献。

当生成器训练完成后, 我们固定生成器的参数, 并通过生成器生成新的数据。然后, 将这些生成的数据合并到负样本数据集中, 并通过重采样正样本数据集来保持正负样本的比例为 1:1。这个步骤的目标是训练出一个更加精确的鉴别器, 能够更好地区分真实数据和生成数据。训练好的鉴别器通过强化其鉴别能力来区分真实数据和生成数据。随着训练的进行, 鉴别器会逐渐变得更加精确, 能够识别出生成器生成的数据。一旦训练出更强的鉴别器, 就再次固定鉴别器的参数, 训练生成器。反复交替训练生成器和鉴别器, 直到达到一个收敛的状态。


## 5.2 数据投毒攻击防御

在数据投毒攻击防御方面, 本研究提出了一种创新的防御策略, 将基于注意力蒸馏的防御算法与传统的权重迁移调节算法相结合, 形成了一种增强的基于注意力蒸馏的知识迁移算法。在本节中, 我们将首先详细介绍注意力蒸馏防御算法的核心机制及其在抵御数据投毒攻击中的作用, 随后阐述如何将其与权重迁移调节算法整合, 构建出完整的基于注意力蒸馏的知识迁移算法框架。这种结合旨在充分利用注意力机制的优势, 提升模型在面对数据投毒攻击时的鲁棒性, 同时优化知识迁移过程中的信息传递效率。

### 5.2.1 基于注意力蒸馏的防御算法

基于注意力蒸馏的防御算法的核心思想是利用注意力机制和知识蒸馏技术, 从深度神经网络中去除后门触发器。具体来说, 假设积液检测模型已经被植入后门, 先用干净的数据集子集对中毒模型进行微调。然后将微调后的中毒模型作为教师模型, 微调前的中毒模型作为学生模型。利用教师模型结合干净数据集子集对学生模型进行迁移学习, 该过程中通过最小化教师模型和学生模型的激活图差异来消除学生模型中的后门, 整体流程如图5-1所示。

具体来说, 以 CNN 网络为例, 假设模型的某一层输出为  $F \in \mathbb{R}^{C \times H \times W}$ , 其中  $C$  代表通道数,  $H$  代表特征图的长度,  $W$  代表特征图的宽度。之后, 通过一个注意力变换将经过激活函数的输出映射到一个单通道的特征图  $\mathbb{R}^{C \times H \times W} \rightarrow \mathbb{R}^{H \times W}$ , 这种注意力变换主要是用于集合各个通道的信息, 其实现方式并不局限于某一种特定的方法, 例如通过均值


 图 5-1 基于注意力蒸馏的防御算法流程<sup>[41]</sup>

来计算：

$$A(x) = \frac{1}{C} \sum_{i=1}^C F_i(x) \quad (5-15)$$

其中， $A(x)$  表示映射后的单通道特征图， $F_i(x)$  表示映射前第  $i$  个通道特征图。基于映射后的特征图，基于注意力蒸馏的防御算法中的注意力蒸馏损失定义如下：

$$\mathcal{L}_{\text{NAD}} = \frac{1}{N} \sum_{i=1}^N \left\| \frac{A(x_i)}{\|A(x_i)\|_2} - \frac{A'(x_i)}{\|A'(x_i)\|_2} \right\|_2 \quad (5-16)$$

其中， $N$  表示模型层数， $A(x_i)$  表示教师模型第  $i$  层输出映射后的特征图， $A'(x_i)$  表示学生模型第  $i$  层输出映射后的特征图。其总体训练损失表示为：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{CE}} + \beta \cdot \mathcal{L}_{\text{NAD}} \quad (5-17)$$

其中， $\mathcal{L}_{\text{CE}}$  表示在干净数据集上衡量的学生网络的分类误差， $\beta$  为控制注意力蒸馏强度的超参数。

### 5.2.2 基于注意力蒸馏的知识迁移算法

由于注意力蒸馏的防御算法本身包含迁移学习的步骤，而本研究所提出的知识迁移权重调节机制也是基于迁移学习完成的。因此，我们结合了注意力蒸馏的防御机制与知识迁移权重调节机制的优势，提出了一种基于注意力蒸馏的知识迁移算法，旨在有效防御页岩气井积液检测联邦学习中的后门攻击。具体而言，假设本地积液检测模型已被植入后门触发器，我们首先从中央服务器接收经过联邦学习优化的局部化中心模型参数。为了生成一个更接近干净数据特征的教师模型，我们使用约 5% 的本地干净数据对局部

化中心模型进行微调。该过程旨在部分消除后门触发器的影响，同时保留模型对本地数据的适应性。微调后的局部化中心模型（教师模型）与本地积液检测模型（学生模型）进入知识迁移阶段。在这一步中，我们重点关注教师模型和学生模型的双注意力增强模块输出的特征图。通过引入注意力蒸馏损失，我们最小化这两个特征图之间的差异，从而促使学生模型学习到更接近教师模型的特征表示。注意力蒸馏损失通过强制学生模型的注意力图与教师模型的注意力图对齐，进一步清除后门触发器的影响，同时增强学生模型对干净数据的分类能力，综合损失函数表示为：

$$\mathcal{L}_{\text{total}} = (1 - \alpha) \cdot CE(P_s(y|x), y) + \alpha \cdot KL(P_t(y|x) || P_s(y|x)) + \beta \cdot \mathcal{L}_{\text{NAD}} \quad (5-18)$$

其中， $(1 - \alpha) \cdot CE(P_s(y|x), y)$  是积液检测模型的稀疏分类交叉熵，衡量模型对真实标签  $y$  的预测误差。 $\alpha \cdot KL(P_t(y|x) || P_s(y|x))$  是局部化中心模型的积液分级结果和积液检测模型的积液分级结果之间的 KL 散度，度量了局部化中心模型对于积液检测模型的差异。 $\beta \cdot \mathcal{L}_{\text{NAD}}$  是注意力蒸馏损失，用于对齐教师模型和学生模型的注意力图。

注意力蒸馏损失的计算方式为教师模型和学生模型特征图的归一化 L2 范数差异，如公式5-16所示。这一过程确保了学生模型在学习过程中能够逐步“忘记”后门特征，转而学习到更符合干净数据的特征表示。需要强调的是，由于双注意力增强模块的输出特征图只有一个通道，所以注意力蒸馏损失计算只依赖该特征图完成。

### 5.3 模型投毒攻击防御

在模型投毒攻击防御方面，本研究提出了一种创新的中心化弹性聚合算法，旨在结合拜占庭弹性聚合算法和中心化加权聚合算法的优势，以增强联邦学习系统对恶意攻击的鲁棒性。在本节中，我们将首先介绍三类常见的拜占庭弹性聚合算法，分析它们在抵御模型投毒攻击中的机制和性能表现。随后，我们将详细阐述中心化弹性聚合算法的设计思路和实现方法，展示其如何通过整合两种聚合算法的优势来提升系统的整体防御能力。

#### 5.3.1 拜占庭弹性聚合算法

页岩气井的生产数据通常具有高度异构性，且不同气井的积液特征差异较大，这使得联邦学习在整合局部化中心模型时容易受到模型投毒攻击或局部异常数据的干扰。拜占庭弹性聚合是联邦学习中一种重要的技术，用于增强联邦学习系统在面对拜占庭攻击时的鲁棒性。拜占庭弹性聚合的目标是通过设计鲁棒的聚合规则，过滤掉这些恶意更新，确保局部化中心模型能够正常收敛。常见的拜占庭弹性聚合方法主要包括以下三种：（1）基于聚类的方法，通过聚类算法将积液检测模型更新分组，剔除异常的聚类，从而减少恶意更新的影响。本研究中，我们采用了 K-Means 聚类算法，聚类的目标是最

小化簇内距离之和，公式如下：

$$\min_{C_k} = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2 \quad (5-19)$$

其中， $C_k$  表示第  $k$  个簇， $\mu_k$  是簇的中心点， $x$  是客户端的模型更新。异常值通常被识别为距离簇中心较远的点或属于稀疏簇的点。

(2) 基于影子模型的方法，局部化中心服务器预先训练一个影子模型，通过对积液检测模型与影子模型的梯度方向，标记并剔除恶意客户端，具体公式为：

$$\text{Score}(\mu_i) = \sum_j \text{sign}(\Delta w_{i,j}, \Delta w_{\text{shadow},j}) \quad (5-20)$$

其中， $\mu_i$  是客户端  $i$  的恶意得分， $\Delta w_{i,j}$  是客户端  $i$  的模型更新， $\Delta w_{\text{shadow},j}$  是影子模型的更新， $\text{sign}$  函数用于判断更新方向的一致性。得分较低的客户端被认为是恶意的并被剔除。

(3) 基于几何中值的方法，利用所有积液检测模型参数的几何中值进行聚合，这种方法对异常值具有较强的鲁棒性。几何中值的计算公式为：

$$w_{\text{median}} = \arg \min_w \sum_i \|w - \mu_i\| \quad (5-21)$$

其中， $\mu_i$  是客户端的模型更新， $\|\cdot\|$  示欧几里得距离。几何中值能够有效抵抗异常值的影响，因为它最小化了到所有点的总距离，而不是像均值那样对异常值敏感。

### 5.3.2 中心化弹性聚合算法

第 4.1.1 节提出的中心化加权聚合算法能够在一定程度上缓解恶意攻击，因为它通过权重分配机制对模型更新的影响进行了调节。如果某个积液检查模型的参数与局部化中心模型的差异过大，这可能意味着该积液检测模型受到了恶意攻击的影响。此时，算法会赋予这个差异较大的积液检测模型更高的权重，从而在一定程度上促使中心模型更偏向这个恶意的局部模型。这种机制看似会加剧恶意模型的影响，但实际上，梯度会在后续的聚合中被“拉回”正常范围，因为下一轮次中，其他正常模型的参数会对其产生更大的“纠正”作用。由于该算法利用了联邦学习多轮训练的特点，允许每个参与方根据自身需求选择最优局部化中心模型。而恶意参与方即使在某一轮中成功影响了局部化中心模型，也无法确保其恶意模型被其他参与方使用。

我们将中心化加权聚合算法与拜占庭弹性聚合算法相结合，提出了一种中心化弹性聚合算法来提升系统的安全性。具体来说，我们分别结合了上述三种拜占庭弹性聚合方法，有效过滤恶意或异常更新。基于聚类的方法，在每轮训练中，将当前局部化中心模型  $\theta^{(t)}$  和上一轮局部化中心模型  $\theta^{(t-1)}$  作为两个聚类中心。对于每个客户端的模型更新  $\theta_i^{(t)}$ ，计算其与两个聚类中心的距离：

$$d_i^{(t)} = \min(\|\theta_i^{(t)} - \theta^{(t)}\|, \|\theta_i^{(t)} - \theta^{(t-1)}\|) \quad (5-22)$$

选择距离当前局部化中心模型  $\theta^{(t-1)}$  更近的客户端模型进行聚合，形成新的局部化中心模型：

$$\theta_{new}^{(t)} = \frac{\sum_{i \in S} \theta_i^{(t)}}{|S|} \quad (5-23)$$

其中， $S$  是满足  $d_i^{(t)} = \|\theta_i^{(t)} - \theta^{(t)}\|$  的积液检测模型集合。

基于影子模型的方法，将当前局部化中心模型  $\theta^{(t)}$  作为影子模型，计算其梯度方向  $\Delta\theta^{(t)}$ 。对于每个积液检测模型  $\theta_i^{(t)}$ ，计算其梯度方向  $\Delta\theta^{(t)}_i$ 。通过梯度方向一致性评估保留正常模型：

$$\text{Score}_i^{(t)} = \frac{\Delta\theta_i^{(t)} \cdot \Delta\theta^{(t)}}{\|\Delta\theta_i^{(t)}\| \|\Delta\theta^{(t)}\|} \quad (5-24)$$

保留满足  $\text{Score}(t)_i > \gamma$  的积液检测模型进行聚合，其中  $\gamma$  是一致性阈值。新的局部化中心模型按照公式5-23进行聚合。

基于几何中值的方法中，将当前局部化中心模型  $\theta^{(t)}$  和所有积液检测模型  $\theta_i^{(t)}$  一起计算几何中值，作为新的局部化中心模型：

$$w_{median} = \arg \min_w \sum_i^N \|w - \theta_i^{(t)}\| + \lambda \|w - \theta^{(t)}\| \quad (5-25)$$

其中， $\lambda$  是一个正则化参数，用于平衡当前局部化中心模型和积液检测模型更新的影响，确保新模型在全局方向上的一致性。

## 5.4 实验与分析

在本章节中，我们围绕隐私保护、模型投毒攻击防御以及数据投毒攻击防御三个方面展开了一系列系统性的实验与分析。

### 5.4.1 隐私保护实验与分析

在本研究中，我们通过一系列实验，深入探究了差分隐私与生成对抗相结合的方案对积液检测模型性能的影响。我们不仅对比了引入生成对抗网络后模型性能的变化，还分析了隐私预算对模型性能和安全性的影响。

#### 5.4.1.1 隐私保护实验结果

表5-1、5-2和5-3详细展示了在三个不同数据集上，采用差分隐私与生成对抗网络相结合的方法对局部模型性能的影响情况。从实验结果来看，采用差分隐私与生成对抗网络相结合的方法在保护数据隐私的同时，对模型性能产生了一定的影响。以数据集 A 为例，隐私保护技术的引入导致三种积液类别的准确率（ACC）分别下降了 0.86%、1.78% 和 1.99%。类似地，在数据集 B 中，ACC 分别下降了 1.23%、1.78% 和 1.99%；而在数据集 C 中，ACC 分别下降了 1.23%、1.89% 和 1.32%。此外，从综合指标来看，三个数据集上的平均 F1 得分均下降了 0.01。这些结果表明，隐私保护技术的引入对模型的预

测精度产生了显著的干扰，部分关键指标（如阳性预测值 PPV、真阳性率 TPR、准确率 ACC 和 F1 得分）在三种类别上均出现了不同程度的下降。

表 5-1 数据集 A 测试集实验结果，○ 内表示相比未采用隐私保护的提升或下降

| 指标  | 正常     | 轻度积液           | 严重积液           | 水淹             | 平均             |
|-----|--------|----------------|----------------|----------------|----------------|
| PPV | 78.66% | 76.47%(-2.45%) | 90.24%(-0.12%) | 97.21%(-1.23%) | 85.65%(-0.95%) |
| FOR | 6.57%  | 5.38%(-1.23%)  | 8.2%(+2.34%)   | 5.55%(+0.56%)  | 6.43%(+1.03%)  |
| FDR | 21.33% | 23.52%(+2.45%) | 9.75%(+0.12%)  | 2.78%(+1.23%)  | 14.35%(+0.95%) |
| NPV | 93.42% | 94.61%(-1.23%) | 91.79%(-2.34%) | 94.44%(-0.56%) | 93.57%(-1.03%) |
| TPR | 79.67% | 85.66%(+0.78%) | 90.26%(-2.9%)  | 90.29%(+0.78%) | 86.47%(-0.33%) |
| FPR | 6.94%  | 6.66%(+0.56%)  | 7.74%(-0.56%)  | 3.15%(+2.45%)  | 6.12%(+0.61%)  |
| FNR | 20.32% | 14.33%(-0.78%) | 9.73%(+2.9%)   | 9.7%(-0.78%)   | 13.52%(+0.34%) |
| TNR | 93.03% | 93.33%(-0.56%) | 92.25%(+0.56%) | 96.84%(-2.45%) | 93.86%(-0.61%) |
| LR+ | 11.44  | 11.59(-2.32)   | 9.5(-1.71)     | 103.46(-23.28) | 34.00(-6.82)   |
| LR- | 0.21   | 0.33(+0.17)    | 0.17(+0.1)     | 0.36(+0.26)    | 0.26(+0.13)    |
| ACC | 89.77% | 91.12%(-0.86%) | 90.58%(-1.78%) | 94.05%(-1.99%) | 91.38%(-1.15%) |
| F1  | 0.79   | 0.80(-0.01)    | 0.89(-0.02)    | 0.91(-0.02)    | 0.85(-0.01)    |

表 5-2 数据集 B 测试集实验结果，○ 内表示相比未采用隐私保护的提升或下降

| 指标  | 正常     | 轻度积液           | 严重积液           | 水淹             | 平均             |
|-----|--------|----------------|----------------|----------------|----------------|
| PPV | 83.75% | 85.7%(-0.56%)  | 84.78%(-0.45%) | 96.49%(-1.23%) | 87.68%(-0.55%) |
| FOR | 6.74%  | 6.63%(+2.45%)  | 6.31%(+2.90%)  | 4.55%(+0.78%)  | 6.06%(+1.54%)  |
| FDR | 16.24% | 14.29%(+0.56%) | 15.22%(+0.45%) | 3.5%(+1.23%)   | 12.30%(+0.55%) |
| NPV | 93.25% | 93.36%(-2.45%) | 93.68%(-2.90%) | 95.44%(-0.78%) | 93.92%(-1.54%) |
| TPR | 80.42% | 81.16%(+0.76%) | 91.88%(-2.34%) | 85.15%(-0.56%) | 84.65%(-0.53%) |
| FPR | 5.44%  | 5.75%(+2.98%)  | 9.76%(+0.67%)  | 2.88%(+2.34%)  | 5.96%(+1.50%)  |
| FNR | 19.57% | 18.83%(-0.76%) | 8.11%(+2.34%)  | 14.84%(+0.56%) | 15.33%(+0.53%) |
| TNR | 94.55% | 94.24%(-2.98%) | 90.23%(-0.67%) | 97.11%(-2.34%) | 94.03%(-1.50%) |
| LR+ | 14.76  | 25.3(-3.69)    | 9.64(-0.72)    | 120.3(-37.27)  | 42.50(-10.42)  |
| LR- | 0.20   | 0.34(+0.14)    | 0.18(+0.12)    | 0.25(+0.11)    | 0.24(+0.09)    |
| ACC | 90.89% | 93%(-1.23%)    | 90.31%(-1.78%) | 94.51%(-1.99%) | 92.18%(-1.24%) |
| F1  | 0.82   | 0.82(-0.01)    | 0.87(-0.02)    | 0.89(-0.02)    | 0.85(-0.01)    |

表5-4则进一步对上述所有数据集的实验结果进行了汇总与平均值统计。PPV 在“轻度积液”、“严重积液”和“水淹”类别上分别下降了 1.26%、0.42% 和 1.82%；NPV 在三个类别上分别下降了 1.90%、2.53% 和 0.67%；ACC 在三个类别上分别下降了 1.10%、1.82% 和 1.77%。在 F1 得分上，“严重积液”类别的受影响程度最大，达到了 0.02，其余类别均为 0.01，然而，FNR 在部分类别上出现上升，例如“严重积液”类别上升了 2.57%。

总体而言，差分隐私与生成对抗网络相结合的方法在保护数据隐私的同时，虽然对模型性能产生了一定的负面影响，但这种下降幅度仍然处于可接受的范围内，并未显著削弱模型的整体实用性。

表 5-3 数据集 C 测试集实验结果, ○ 内表示相比未采用隐私保护的提升或下降

| 指标  | 正常     | 轻度积液           | 严重积液           | 水淹             | 平均             |
|-----|--------|----------------|----------------|----------------|----------------|
| PPV | 86.47% | 89.16%(-0.78%) | 87.69%(-0.67%) | 97.02%(-2.98%) | 90.09%(-1.11%) |
| FOR | 7.54%  | 5.08%(+1.99)   | 4.32%(+2.35%)  | 5.01%(+0.67)   | 5.49%(+1.25)   |
| FDR | 13.52% | 10.83%(+0.78%) | 12.30%(+0.67%) | 2.98%(+2.98%)  | 9.91%(+1.11%)  |
| NPV | 92.45% | 94.91%(-1.99%) | 95.65%(-2.35)  | 94.98%(-0.67%) | 94.50%(-1.25%) |
| TPR | 79.02% | 83.04%(+0.56%) | 94.29%(-2.47%) | 85.60%(+0.85%) | 85.48%(-0.27%) |
| FPR | 4.58%  | 4.10%(+2.45%)  | 8.54%(+1.12%)  | 2.14%(+2.14%)  | 4.84%(+1.43%)  |
| FNR | 20.97% | 16.95%(-0.56%) | 5.70%(+2.47%)  | 14.39%(-0.85%) | 14.50%(+0.27%) |
| TNR | 95.41% | 95.89%(-2.45%) | 91.45%(-1.12%) | 97.86%(-2.14%) | 95.15%(-1.43%) |
| LR+ | 17.21  | 45.17(-4.77)   | 11.39(-1.63)   | 117.4          | 47.79          |
| LR- | 0.21   | 0.24(+0.07)    | 0.08(+0.05)    | 0.20(+0.05)    | 0.18(+0.04)    |
| ACC | 90.97% | 95.68%(-1.23%) | 92.22%(-1.89%) | 95.17%(-1.32%) | 93.51%(-1.11%) |
| F1  | 0.82   | 0.85(-0.01)    | 0.90(-0.02)    | 0.90(-0.01)    | 0.86(-0.01)    |

表 5-4 三个数据集测试集上的平均实验结果, ○ 内表示相比未采用隐私保护的提升或下降

| 指标  | 正常     | 轻度积液           | 严重积液           | 水淹             | 平均             |
|-----|--------|----------------|----------------|----------------|----------------|
| PPV | 82.96% | 83.78%(-1.26%) | 87.56%(-0.42%) | 96.90%(-1.82%) | 87.80%(-0.87%) |
| FOR | 6.95%  | 5.70%(+1.90%)  | 6.29%(+2.53%)  | 5.03%(+0.67%)  | 5.99%(+1.27%)  |
| FDR | 17.03% | 16.21%(+1.26%) | 12.43%(+0.42%) | 3.09%(+1.82%)  | 12.19%(+0.88%) |
| NPV | 93.04% | 94.29%(-1.90%) | 93.70%(-2.53%) | 94.95%(-0.67%) | 93.99%(-1.27%) |
| TPR | 79.70% | 83.28%(+0.70%) | 92.14%(-2.57%) | 87.01%(+0.36%) | 85.53%(-0.38%) |
| FPR | 5.65%  | 5.50%(-2.00%)  | 8.68%(+0.41%)  | 2.72%(+2.31%)  | 5.63%(+1.17%)  |
| FNR | 20.29% | 16.70%(-0.70%) | 7.84%(+2.57%)  | 12.97%(-0.36%) | 14.45%(+0.38%) |
| TNR | 94.33% | 94.48%(-2.00%) | 91.31%(-0.41%) | 97.27%(-2.31%) | 94.34%(-1.18%) |
| LR+ | 14.47  | 27.35(-3.59)   | 10.17(-1.36)   | 113.72         | 41.42          |
| LR- | 0.21   | 0.30(+0.13)    | 0.14(+0.09)    | 0.27(+0.14)    | 0.24(+0.10)    |
| ACC | 90.54% | 93.27%(-1.10%) | 91.03%(-1.82%) | 94.57%(-1.77%) | 92.35%(-1.17%) |
| F1  | 0.81   | 0.82(-0.01)    | 0.88(-0.02)    | 0.90(-0.01)    | 0.85(-0.01)    |

#### 5.4.1.2 对比实验结果

我们将实验结果中的 F1 得分与仅使用差分隐私的积液检测模型的 F1 得分相比较, 实验结果如图5-2所示。在多个不同数据集上, 引入生成对抗网络后, 数据集 A 中轻度积液、严重积液和水淹的 F1 得分分别提高了 0.04、0.02 和 0.08; 数据集 B 中各类别的 F1 得分均提高了 0.04; 数据集 C 中轻度积液、严重积液和水淹的 F1 得分分别提高了 0.07、0.04 和 0.02。这些结果表明, 生成对抗网络通过生成高质量的合成数据, 有效增强了模型对不同积液类型的识别能力, 同时弥补了仅使用差分隐私时可能带来的性能损失。

为了更全面地评估隐私保护的安全性, 通过计算差分隐私前后模型参数的 L2 范数来量化加噪强度:

$$D = \frac{1}{n} \sum_{i=1}^n \|\theta'_i - \theta_i\|_2 \quad (5-26)$$

其中,  $n$  是参数的总数,  $\theta'_i$  是加噪后的参数,  $\theta_i$  是加噪前的参数。表5-5展示了引入生成




图 5-2 不同加噪方式下三个数据集测试集实验结果

对抗网络后，加噪强度的变化情况。结果显示，仅使用差分隐私时，数据集 A、B、C 的加噪强度分别为 1.376、1.368 和 1.492，平均加噪强度为 1.412。而当引入生成对抗网络后，加噪强度分别下降到 1.328、1.314 和 1.402，平均加噪强度下降到 1.348，整体下降幅度为 0.064。结果表明，尽管引入生成对抗网络后加噪强度略有下降，但整体影响较小。具体来看，数据集 A、B、C 的加噪强度分别仅下降了 0.048、0.054 和 0.090，平均降幅仅为 4.5%。说明生成对抗网络在优化模型性能的同时，对隐私保护性能的影响微乎其微。因此，结合生成对抗网络的隐私保护机制能够在不显著降低隐私保护强度的前提下，进一步提升模型的性能。

表 5-5 不加噪方式下三个数据集上局部模型参数的加噪强度，() 内表示下降幅度

| 加噪方式        | 数据集 A         | 数据集 B         | 数据集 C         | 平均            |
|-------------|---------------|---------------|---------------|---------------|
| 差分隐私        | 1.376         | 1.368         | 1.492         | 1.412         |
| 差分隐私 + 生成对抗 | 1.328(-0.048) | 1.314(-0.054) | 1.402(-0.090) | 1.348(-0.064) |

5.4.1.3 隐私预算的影响

隐私预算决定了在数据中添加噪声的量， $\epsilon$  值越小，添加的噪声越大，隐私保护越强，但数据的准确性和可用性会降低。图5-3清晰地展示了在不同隐私预算条件下，三个数据集上局部模型参数在应用差分隐私技术后的加噪强度变化情况。当  $\epsilon$  值从 1 降低到 0.1 时，加噪强度显著增加。例如，在数据集 A 上，仅使用差分隐私时的加噪强度从 0.293 增加到 2.950，表明隐私保护强度显著增强，但数据的准确性和可用性相应降低。实验中，我们也对比了仅使用差分隐私和结合生成对抗网络时的加噪强度。在所有隐私预算条件下，引入生成对抗网络后，加噪强度均有所降低。例如，在  $\epsilon = 0.5$  时，数据集 A 的加噪强度从 1.376 降低到 1.328，数据集 B 从 1.368 降低到 1.314，数据集 C 从 1.492 降低到 1.402。

表 5-6 展示了在不同隐私预算下，三个数据集上积液检测模型的 F1 得分变化情况。




图 5-3 不同隐私预算下三个数据集上积液检测模型参数的加噪强度（\* 代表使用了生成对抗网络）

从结果中可以看出，隐私预算对模型性能有显著影响。随着  $\epsilon$  值的减小，模型性能逐渐下降。例如，当  $\epsilon$  为 1 和 0.7 时，平均 F1 得分仅略有下降，分别为 0.86 和 0.85。然而，当  $\epsilon$  进一步降低到 0.3 和 0.1 时，平均 F1 得分显著下降，分别为 0.80 和 0.67。

表 5-6 不同隐私预算下三个数据集上积液检测模型的 F1 得分

| 隐私预算 | 数据集 A | 数据集 B | 数据集 C | 平均   |
|------|-------|-------|-------|------|
| 1    | 0.86  | 0.86  | 0.87  | 0.86 |
| 0.7  | 0.85  | 0.86  | 0.86  | 0.85 |
| 0.5  | 0.85  | 0.85  | 0.86  | 0.85 |
| 0.3  | 0.79  | 0.81  | 0.82  | 0.80 |
| 0.1  | 0.67  | 0.66  | 0.70  | 0.67 |

总体上讲，当  $\epsilon$  值较大时，隐私保护强度较低，但数据可用性较高。当  $\epsilon$  值较小时，隐私保护强度较高，但数据可用性较低。通过引入生成对抗网络，可以在一定程度上优化这种权衡，实现更强的隐私保护和更优的模型性能。

5.4.1.4 噪声函数的影响

本研究进一步研究了不同噪声函数对所提出的隐私保护方法的影响，结果如表5-7所示。具体而言，实验对比了拉普拉斯噪声函数、高斯噪声函数和指数噪声函数在隐私保护场景下的性能表现。结果表明，三种噪声函数均在隐私保护与模型效用之间取得了良好的平衡，并表现出优异的效果。在局部模型的评估中，采用拉普拉斯噪声函数、高斯噪声函数和指数噪声函数的模型平均 F1 分数分别达到了 0.85、0.84 和 0.83。这一结果表明，尽管不同噪声函数在隐私保护机制上存在差异，但它们均能有效支持隐私保护方法的实施，并在模型性能上展现出较高的鲁棒性。

表 5-7 不加噪声函数下三个数据集上局部模型参数的性能

| 噪声函数 | 数据集 A | 数据集 B | 数据集 C | 平均   |
|------|-------|-------|-------|------|
| 拉普拉斯 | 0.85  | 0.85  | 0.86  | 0.85 |
| 高斯   | 0.85  | 0.84  | 0.85  | 0.84 |
| 指数   | 0.83  | 0.82  | 0.85  | 0.83 |

## 5.4.2 数据投毒攻击防御实验与分析

本研究主要对基于注意力蒸馏的知识迁移算法的防御性能进行了系统性评估。首先，针对五种常见的模型投毒攻击手段，我们详细分析了这些攻击对算法的攻击成功率和模型性能的影响，以验证算法在不同攻击类型下的鲁棒性。其次，我们进一步探讨了基于注意力蒸馏的知识迁移算法中干净数据微调比例的变化对防御性能的影响，通过调整干净数据的微调比例，研究其对攻击成功率和模型性能的具体作用。

### 5.4.2.1 数据投毒攻击防御实验结果

本研究采用了 5 种不同的攻击手段来验证基于注意力蒸馏的知识迁移算法的防御性能，攻击包括：BadNets 攻击<sup>[42]</sup>、木马攻击（Trojan）<sup>[43]</sup>、混合攻击（Blend）<sup>[44]</sup>、清洁标签攻击（CL）<sup>[45]</sup>、正弦信号攻击（SIG）<sup>[46]</sup>，所有积液检测模型微调所使用的干净数据比例均占总数据的 5%。

表 5-8 不同数据投毒攻击对基于注意力蒸馏知识迁移算法的攻击成功率（ASR）和 F1 得分的影响

| 攻击类型    | 攻击方 | 数据集 A  |             | 数据集 B  |             | 数据集 C  |             | 平均     |      |
|---------|-----|--------|-------------|--------|-------------|--------|-------------|--------|------|
|         |     | ASR    | F1          | ASR    | F1          | ASR    | F1          | ASR    | F1   |
| BadNets | A   | /      | /           | 5.61%  | 0.83(-0.02) | 5.36%  | 0.84(-0.02) | 5.48%  | 0.83 |
|         | B   | 5.29%  | 0.84(-0.01) | /      | /           | 5.68%  | 0.84(-0.02) | 5.48%  | 0.84 |
|         | C   | 5.62%  | 0.83(-0.02) | 5.39%  | 0.83(-0.02) | /      | /           | 5.50%  | 0.83 |
| Trojan  | A   | /      | /           | 23.08% | 0.78(-0.05) | 20.30% | 0.82(-0.04) | 21.69% | 0.80 |
|         | B   | 18.13% | 0.82(-0.03) | /      | /           | 23.53% | 0.82(-0.04) | 20.83% | 0.82 |
|         | C   | 18.93% | 0.81(-0.04) | 21.93% | 0.80(-0.05) | /      | /           | 20.43% | 0.80 |
| Blend   | A   | /      | /           | 4.60%  | 0.83(-0.02) | 4.07%  | 0.85(-0.01) | 4.33%  | 0.84 |
|         | B   | 3.81%  | 0.84(-0.01) | /      | /           | 4.51%  | 0.84(-0.02) | 4.16%  | 0.84 |
|         | C   | 4.02%  | 0.84(-0.01) | 4.37%  | 0.83(-0.02) | /      | /           | 4.19%  | 0.83 |
| CL      | A   | /      | /           | 11.94% | 0.82(-0.03) | 12.30% | 0.83(-0.03) | 12.12% | 0.82 |
|         | B   | 8.36%  | 0.82(-0.02) | /      | /           | 10.65% | 0.84(-0.02) | 9.50%  | 0.83 |
|         | C   | 7.98%  | 0.83(-0.02) | 9.68%  | 0.82(-0.03) | /      | /           | 8.83%  | 0.82 |
| SIG     | A   | /      | /           | 4.19%  | 0.83(-0.02) | 5.54%  | 0.84(-0.02) | 4.86%  | 0.83 |
|         | B   | 1.77%  | 0.84(-0.01) | /      | /           | 3.50%  | 0.85(-0.01) | 2.63%  | 0.84 |
|         | C   | 1.10%  | 0.84(-0.01) | 3.10%  | 0.84(-0.01) | /      | /           | 2.10%  | 0.84 |

表5-8展示了不同数据投毒攻击对基于注意力蒸馏的知识迁移算法的攻击成功率（ASR）和性能（F1）的影响。结果显示，不同攻击类型和攻击方对算法的影响存在显著差异。以 A 作为攻击方为例，BadNets 攻击在数据集 B 和 C 上，ASR 分别为 5.61% 和 5.36%，F1 得分均下降了 0.02。Trojan 攻击的 ASR 和 F1 得分下降更为显著，平均 ASR

达到 21.69%，F1 得分下降了约 0.05。相比之下，Blend 攻击的平均 ASR 仅为 4.33%，F1 得分下降了约 0.02，表明其对模型性能的影响较小。CL 攻击和 SIG 攻击的 ASR 和 F1 得分下降介于两者之间，其中 SIG 攻击的平均 ASR 为 4.86%，F1 得分下降了 0.02。总体来看，Blend 和 SIG 攻击对模型性能的影响相对较小，而 Trojan 攻击对模型性能的影响最为显著。这些结果表明，不同攻击类型对基于注意力蒸馏的知识迁移算法的攻击成功率和性能影响各异，其中 Trojan 攻击具有较高的攻击成功率和较大的性能下降，而 Blend 和 SIG 攻击的影响相对较小。

#### 5.4.2.2 微调数据比例的影响

此外，本研究进一步考察了不同比例干净数据微调对数据投毒攻击成功率的影响，结果如图5-4所示。具体来看，各类攻击在未进行干净数据微调时的成功率高达 100%，其中，BadNets 攻击随着干净数据微调比例增加至 20%，其成功率降至 2.12%，下降幅度最为显著。Trojan 攻击在 20% 干净数据微调后降至 9.61%，显示出较强的抗性，但成功率仍大幅下降。Blend 攻击降至 1.79%，CL 攻击降至 3.46%，SIG 攻击降至 1.32%。上述攻击随着干净数据比例增加，攻击成功率显著降低。总体而言，SIG 攻击在干净数据微调后表现出最低的成功率，表明其对干净数据微调的防御措施最为敏感。相比之下，Trojan 攻击虽然在微调后仍保持较高的成功率，但其下降幅度也较为明显。这些结果表明，基于注意力蒸馏的知识迁移算法是一种有效的防御策略，能够在不同程度上抵御各种数据投毒攻击，显著降低攻击的成功率，从而增强模型的鲁棒性和安全性。




图 5-4 不同比例干净数据微调后模型投毒攻击的成功率

#### 5.4.3 模型投毒攻击防御实验与分析

在模型投毒攻击防御实验与分析章节中，我们深入研究了不同投毒比例下模型投毒攻击对基于聚类方法的中心化弹性聚合算法的影响，特别是其对模型性能（以 F1 得分衡量）的具体作用。此外，我们进一步分析了三种不同类型的中心化弹性聚合方法（包

括聚类方法、影子模型方法和几何中值方法) 在面对模型投毒攻击时的防御性能, 对比了它们在不同投毒比例下的 F1 得分表现, 以评估各自在抵御攻击时的鲁棒性。

#### 5.4.3.1 模型投毒攻击防御实验结果

在本实验中, 我们研究了不同投毒比例下模型投毒攻击对基于聚类方法的中心化弹性聚合算法性能 (以 F1 得分衡量) 的影响。实验涉及两种攻击类型: 内积操纵攻击<sup>[47]</sup>和伪装攻击<sup>[48]</sup>。这两种攻击分别通过使聚合梯度的内积为负和伪装模型更新来干扰联邦学习过程。我们模拟了攻击方篡改不同比例的本地积液检测模型参数, 设置五个投毒比例分别为 20%、40%、60%、80% 和 100%, 以研究攻击强度对算法性能的影响。实验在三个数据集上进行, 以评估中心化弹性聚合算法在面对不同攻击类型和投毒比例时的鲁棒性。实验中, 每个数据集分别对应两种攻击类型, 记录了在不同投毒比例下的 F1 得分, 并计算了与未受攻击时的性能差异。

表 5-9 不同投毒比例下模型投毒攻击对基于聚类方法的中心化弹性聚合算法的 F1 得分影响

| 投毒比例 | 攻击方 | 数据集 A       |             | 数据集 B       |             | 数据集 C       |             | 平均   |      |
|------|-----|-------------|-------------|-------------|-------------|-------------|-------------|------|------|
|      |     | 内积操纵        | 伪装          | 内积操纵        | 伪装          | 内积操纵        | 伪装          | 内积操纵 | 伪装   |
| 20%  | A   | /           | /           | 0.85        | 0.84(-0.01) | 0.86        | 0.86        | 0.85 | 0.85 |
|      | B   | 0.85        | 0.85        | /           | /           | 0.86        | 0.86        | 0.85 | 0.85 |
|      | C   | 0.85        | 0.85        | 0.85        | 0.85        | /           | /           | 0.85 | 0.85 |
| 40%  | A   | /           | /           | 0.85        | 0.84(-0.01) | 0.85(-0.01) | 0.85(-0.01) | 0.85 | 0.84 |
|      | B   | 0.84(-0.01) | 0.84(-0.01) | /           | /           | 0.85(-0.01) | 0.85        | 0.84 | 0.84 |
|      | C   | 0.84(-0.01) | 0.84(-0.01) | 0.84(-0.01) | 0.84(-0.01) | /           | /           | 0.84 | 0.84 |
| 60%  | A   | /           | /           | 0.83(-0.02) | 0.84(-0.01) | 0.83(-0.03) | 0.84(-0.02) | 0.83 | 0.84 |
|      | B   | 0.80(-0.05) | 0.83(-0.02) | /           | /           | 0.83(-0.03) | 0.85(-0.01) | 0.81 | 0.84 |
|      | C   | 0.83(-0.02) | 0.84(-0.01) | 0.85(-0.01) | 0.85(-0.01) | /           | /           | 0.84 | 0.84 |
| 80%  | A   | /           | /           | 0.84(-0.01) | 0.83(-0.02) | 0.85(-0.01) | 0.84(-0.02) | 0.84 | 0.83 |
|      | B   | 0.84(-0.01) | 0.83(-0.02) | /           | /           | 0.85(-0.01) | 0.84(-0.02) | 0.84 | 0.84 |
|      | C   | 0.84(-0.01) | 0.83(-0.02) | 0.85        | 0.83(-0.02) | /           | /           | 0.84 | 0.83 |
| 100% | A   | /           | /           | 0.85        | 0.82(-0.03) | 0.86        | 0.82(-0.04) | 0.85 | 0.82 |
|      | B   | 0.85        | 0.83(-0.02) | /           | /           | 0.86        | 0.83(-0.03) | 0.85 | 0.83 |
|      | C   | 0.85        | 0.83(-0.04) | 0.85        | 0.83(-0.02) | /           | /           | 0.85 | 0.83 |

实验结果如表5-9所示, 对于内积攻击, 以 A 作为攻击方为例, 在较低投毒比例 (20%) 下, 数据集 B 和 C 的 F1 得分分别为 0.85 和 0.86, 与未受攻击时相比几乎没有下降, 表明中心化弹性聚合算法在低投毒比例下对内积操纵攻击具有较强的鲁棒性。随着投毒比例增加到 40% 和 60%, F1 得分开始出现下降, 例如在 60% 投毒比例下, 数据集 B 的 F1 得分下降到 0.83 (下降 0.02), 数据集 C 的 F1 得分下降到 0.83 (下降 0.03)。这表明内积操纵攻击在较高投毒比例下对模型性能的影响逐渐增大。然而, 在 80% 和 100% 投毒比例下, F1 得分反而有所回升, 基本与 20% 投毒比例时持平, 例如数据集 B 在 100% 投毒比例下 F1 得分为 0.85。这表明中心化弹性聚合算法在高投毒比例下能够有效检测并消除内积操纵攻击的影响, 从而保持模型性能的稳定。

对于伪装攻击, 以 A 作为攻击方为例, 在 20% 投毒比例下, 数据集 B 的 F1 得分下

降到 0.84（下降 0.01）。随着投毒比例增加，F1 得分进一步下降，例如在 80% 投毒比例下，数据集 B 的 F1 得分下降到 0.83（下降 0.02），数据集 C 的 F1 得分下降到 0.84（下降 0.02）。在 100% 投毒比例下，数据集 B 和 C 的 F1 得分分别下降到 0.82（下降 0.03）和 0.82（下降 0.04），显示出伪装攻击在极端情况下对模型性能的有一定负面影响。总体而言，中心化弹性聚合算法通过其鲁棒的聚合规则和动态权重分配机制，在高比例恶意更新的场景下依然能够维护全局模型的准确性和稳定性。

### 5.4.3.2 对比实验结果

除了基于聚类的中心化弹性聚合算法外，本研究还对比了基于影子模型和基于几何中值的中心化弹性聚合算法，结果如图5-5和5-6所示。对于内积操纵攻击，基于聚类的中心化弹性聚合方法在投毒比例为 20% 时，F1 得分为 0.85，随着投毒比例增加到 60%，F1 得分下降到 0.82，但在 80% 和 100% 投毒比例下，F1 得分回升至 0.84 和 0.85，与 20% 投毒比例时持平，平均 F1 得分为 0.84。基于影子模型的中心化弹性聚合算法在 20% 投毒比例下 F1 得分为 0.85，随着投毒比例增加，F1 得分逐渐下降，到 60% 投毒比例时为 0.83，80% 和 100% 投毒比例下 F1 得分均为 0.83，平均 F1 得分为 0.83。基于几何中值的中心化弹性聚合算法在 20% 投毒比例下 F1 得分为 0.85，40% 投毒比例时下降到 0.83，60% 投毒比例时进一步下降到 0.80，但在 80% 和 100% 投毒比例下 F1 得分回升至 0.84 和 0.85，平均 F1 得分为 0.83。总体来看，基于聚类的中心化弹性聚合算法在高投毒比例下对内积操纵攻击的防御效果最为显著，能够有效保持模型性能的稳定。




图 5-5 不同投毒比例下内积操纵攻击对不同中心化弹性聚合算法的 F1 得分影响

对于伪装攻击，基于聚类的中心化弹性聚合方法在投毒比例从 20% 增加到 60% 时，F1 得分从 0.85 下降到 0.84，随着投毒比例进一步增加到 80% 和 100%，F1 得分略有下降，最终平均得分为 0.83。基于影子模型的中心化弹性聚合算法的 F1 得分随着投毒比例的增加呈现出较为明显的下降趋势，从 20% 投毒比例时的 0.84 下降到 60% 时的 0.78，最终在 100% 投毒比例下回升到 0.81，平均得分为 0.80。基于几何中值的中心化弹性聚

合算法表现出较好的稳定性，其 F1 得分在不同投毒比例下波动较小，从 20% 投毒比例时的 0.85 下降到 60% 时的 0.80，随后在 80% 和 100% 投毒比例下回升至 0.84 和 0.83，平均得分为 0.84。总体而言，中心化弹性聚合算法在面对伪装攻击时，几何中值算法表现最为稳定，聚类算法次之，而影子模型算法在较高投毒比例下防御效果相对较弱。




图 5-6 不同投毒比例下伪装攻击对不同中心化弹性聚合算法的 F1 得分影响

## 5.5 本章小结

本章首先提出了一种结合差分隐私和生成对抗网络的方法，用于在联邦学习中保护隐私。差分隐私通过添加噪声保护用户数据隐私，但可能降低模型精度。为此，引入生成对抗网络生成高质量的合成数据，从而在保证隐私的同时，显著减轻差分隐私对模型精度的负面影响。实验结果表明，该方法在隐私保护和模型性能之间取得了良好的平衡，为联邦学习中的隐私保护提供了有效解决方案。

针对联邦学习中的模型投毒攻击问题，本章将基于注意力蒸馏的防御算法引入联邦学习框架。并提出了一种基于注意力蒸馏的知识迁移算法，有效抵御恶意参与方的数据投毒攻击。实验验证了该算法在联邦学习中的有效性，能够显著提高模型的鲁棒性，确保全局模型的准确性和安全性。该方法为联邦学习中的数据投毒攻击防御提供了新的思路。

最后，为有效防御模型投毒攻击，本章结合中心化加权聚合算法和拜占庭弹性聚合算法，提出了一种中心化弹性聚合算法。其中，中心化加权聚合根据参与方的贡献动态调整权重，而拜占庭弹性聚合则通过鲁棒的聚合策略抵御恶意数据的影响，两者的结合提高了模型对数据投毒攻击的防御能力。实验结果表明，该方法在多种攻击场景下均表现出色，为联邦学习中的模型投毒攻击防御提供了可靠的解决方案。

## 第 6 章 总结与展望

### 6.1 本文工作总结

天然气作为现代社会的关键能源，其稳定供应对国家能源安全至关重要。然而，随着常规天然气资源的逐渐枯竭，开发重点已转向非常规储层，尤其是页岩气。中国在四川盆地、鄂尔多斯盆地和塔里木盆地等地拥有丰富的页岩气资源，为国家能源储备提供了重要支撑。但与此同时，页岩气开采过程中井筒积液问题尤为突出。由于页岩气储层孔隙小、裂缝少、渗透率低，气体释放缓慢，且开采过程中的加压技术会引入液体，进一步加剧积液问题，导致天然气流动受阻，严重影响开采效率。

数据驱动方法在井筒积液检测领域展现出巨大潜力，但在实际应用中仍面临诸多挑战。首先，有监督学习在生产环境中难以获取足够标签数据，因为现场运维台账通常不记录积液的具体时点，而人工标注成本极高。其次，无监督学习因积液过程的渐进性难以设定异常阈值，且聚类算法在缺乏标签的情况下容易将不同工况数据误归类。此外，国内页岩气藏的非均质性显著，不同区块的地质条件和施工工艺存在差异，导致积液机制和流体特征因区域而异，进一步限制了数据驱动模型的检测效果。最后，数据驱动模型在生产环境中还面临安全风险。石油天然气行业作为关键基础设施，数据泄露和恶意攻击可能导致模型失效或错误决策，尽管已有加密和差分隐私等技术，但现有防御措施仍不够健壮。这些问题制约了数据驱动模型在井筒积液检测中的有效应用，亟待解决。针对上述挑战，本文主要完成了三方面的工作，旨在提升页岩气井积液检测的准确性、模型协同优化的效率以及系统的鲁棒性。

首先，本文提出了一种基于半监督学习的二阶段页岩气井积液检测模型。第一阶段采用 LSTM 自编码器模型，通过无监督学习检测页岩气井中的积液情况。该模型能够自动学习数据中的时间序列特征，有效识别积液的存在。第二阶段是一个组合神经网络模型，包括双注意力增强模块、MultiRocket 网络和 MLP 网络，用于对积液的严重程度进行分级。其中，双注意力增强模块是本文的一个创新性模块，能够通过通道注意力和空间注意力机制，增强模型对关键特征的捕捉能力，从而提高积液分级的准确性。此外，第二阶段还采用了半监督学习策略，充分利用未标记数据，进一步提升模型的性能，在三个数据集上的平均 F1 得分分别达到了 0.82，0.83 和 0.86。

其次，针对页岩气井积液检测任务中的分布式数据特点，本文提出了一种基于联邦学习的模型协同优化方法。该方法引入了局部化中心模型思想，通过设计一种动态双向权重调节机制，实现了全局模型与局部模型之间的高效协同优化。该机制包括两个部分：中心化加权聚合算法和知识迁移权重调节算法。中心化加权聚合算法通过动态调整客户端权重，确保全局模型的稳定性和收敛性；知识迁移权重调节算法则通过知识蒸馏技术，将局部化中心模型的知识迁移到积液检测模型中，进一步提升局部模型的性能。

这种协同优化机制提高了模型的整体性能，在三个数据集上的平均 F1 得分分别增加了 0.04、0.03 和 0.01。

最后，为了提升联邦学习系统的安全性，本文深入研究了针对投毒攻击的防御算法。在隐私保护方面，结合了差分隐私技术和生成对抗网络，通过在数据中添加噪声和生成合成数据，保护用户隐私的同时提升模型的鲁棒性。针对数据投毒攻击，本文在知识迁移权重调节算法的基础上，结合基于注意力蒸馏的防御算法，形成了一种基于注意力蒸馏的知识迁移算法。该算法将注意力机制和知识蒸馏技术相结合，从而抵御恶意数据的干扰。针对模型投毒攻击，本文将拜占庭弹性聚合与中心化加权聚合相结合，形成了一种中心化弹性聚合算法。该算法通过鲁棒的聚合规则和动态权重调整机制，有效抵御恶意参与方的攻击，确保局部化中心模型的稳定性和准确性。即使在攻击强度最高、投毒比例最大的条件下，数据投毒攻击导致的积液检测模型平均 F1 得分下降幅度仍然较小，分别仅下降了 0.05、0.02 和 0.03。

## 6.2 未来工作展望

本研究针对页岩气开采中的井筒积液检测问题，提出了一系列创新方法，包括二阶段模型、个性化联邦学习框架以及隐私保护与攻击防御技术，显著提升了模型的检测性能、泛化能力和安全性。然而，随着技术的不断发展和实际应用场景的复杂性增加，仍有许多值得进一步探索的方向。以下是未来工作的展望：

(1) 当前的积液检测模型主要依赖于生产数据（如压力、流量等），但实际生产中还存在其他类型的传感器数据（如声波、振动等）。未来可以探索多模态数据融合技术，将不同类型的数据整合到一个统一的模型框架中。例如，通过设计多模态特征提取模块和融合机制，充分利用不同类型数据的优势，进一步提升积液检测的准确性和可靠性。

(2) 个性化联邦学习在解决非均质性问题方面取得了显著进展，但模型训练效率和资源消耗仍有待优化。未来可以探索更高效的通信协议和模型压缩技术，以减少联邦学习过程中的通信开销。例如，通过模型剪枝和量化技术，降低模型参数的传输量，同时保持模型性能。此外，可以研究更灵活的动态权重调节机制，使其能够自适应地根据数据分布和模型性能动态调整权重，进一步提升模型的泛化能力。

(3) 随着联邦学习在关键基础设施中的应用增加，隐私保护和模型安全性的重要性愈发凸显。未来可以进一步探索隐私保护技术的优化，例如结合同态加密与差分隐私，以实现更强大的隐私保护能力。同态加密允许在加密数据上直接进行计算，从而避免数据泄露风险。在攻击防御方面，可以研究更先进的防御算法，如基于零知识证明的验证机制，以确保参与方提交的模型更新是可信的，从而进一步增强联邦学习框架的鲁棒性。

综上所述，未来工作将围绕模型优化、隐私保护、多模态融合等方向展开。通过这些研究方向的探索和实践，有望进一步提升井筒积液检测技术的性能和实用性，为页岩气开采及其他相关领域的发展提供更有力的支持。

## 致 谢

时光荏苒，岁月如梭。在完成这篇论文的漫长旅程中，我经历了无数个日夜的思考、探索和写作，也收获了来自各方的关怀与支持。此刻，站在学术旅程的一个重要节点上，我怀着无比感激的心情，向每一位在我求学和研究过程中给予帮助的人致以最诚挚的感谢。

首先，我要向我的导师致以最深的敬意和感谢，她不仅在学术上给予了我严谨的指导和宝贵的意见，更在生活中给予了我无微不至的关怀。从论文选题到研究方法的确定，从实验设计到结果分析，再到最后的论文撰写，每一步都离不开导师的悉心指导。导师的严谨治学态度和对学术的执着追求，为我树立了榜样，也激励我在未来的学术道路上不断前行。在与导师的每一次交流中，我都能感受到她对学术的热情和对学生的关爱，这些都将成为我一生的宝贵财富。

感谢我的研究团队，你们在实验过程中与我并肩作战，共同攻克了一个又一个难题。感谢你们的智慧、耐心和团队精神，让我在研究过程中感受到合作的力量和乐趣。同时，感谢实验室的其他同学，你们的鼓励和支持是我不断前进的动力。在实验室的每一天，我们相互学习、相互帮助，共同成长。感谢你们为我创造了一个充满活力和温暖的学术环境。

感谢我的家人，我的父母、兄弟姐妹。你们的理解和支持是我最坚实的后盾。在我最疲惫和困惑的时候，是你们的鼓励让我重新振作，是你们的陪伴让我感受到温暖和力量。感谢你们在我求学的道路上始终如一的支持，你们的爱是我最强大的动力源泉。

最后，感谢所有给予我帮助和支持的老师 and 同学，感谢学校提供的学术环境和研究资源，让我有机会在这里追求我的学术梦想。感谢每一位在我学术旅程中给予帮助的人，你们的支持是我前进的动力，也是我最宝贵的财富。

## 参考文献

- [1] 中国互联网络信息中心. 第 56 次中国互联网络发展状况统计报告[R/OL]. 中国互联网络信息中心. 2025. <https://www.cnnic.net/n4/2025/0721/c326-11327.html>.
- [2] PARK H, SHIN D, PARK C, et al. Unsupervised Machine Learning Methods for Anomaly Detection in Network Packets[J]. Electronics, 2025.
- [3] MIRSKY Y, DOITSHMAN D, ELOVICI Y, et al. Kitsune: An Ensemble of Autoencoders for Online Network Intrusion Detection[J]. Network and Distributed System Security Symposium (NDSS), 2018.
- [4] LANSKY J, ALI S, MOHAMMADI M, et al. Deep learning-based intrusion detection systems: a systematic review[J]. IEEE Access, 2021, 9: 101574-101599.
- [5] SHI L, et al. Network Intrusion Detection Based on Transformer and BiLSTM[J]. Computer Engineering and Applications, 2022, 58(22): 123-131.
- [6] TULI S, CASALE G, JENNINGS N R. Tranad: Deep transformer networks for anomaly detection in multivariate time series data[J]. arXiv preprint arXiv:2201.07284, 2022.
- [7] DING K, LI J, BHANUSHALI R, et al. Deep Anomaly Detection on Attributed Networks [C]//Proceedings of the 2019 SIAM International Conference on Data Mining (SDM). SIAM, 2019.
- [8] ZERVEAS G, JAYARAMAN S, PATEL D, et al. A Transformer-Based Framework for Multivariate Time Series Representation Learning[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. ACM, 2021.
- [9] XU H, SUN Z, CAO Y, et al. A data-driven approach for intrusion and anomaly detection using automated machine learning for the Internet of Things[J]. Soft Computing, 2023, 27(19): 14469-14481.
- [10] ÖZÇELEBI I, MARTTIN V. Comparative Evaluation of Ensemble and Tree-Based Machine Learning Algorithms for Network Intrusion Detection[J]. Journal of Electronic & Information Systems, 2025.
- [11] Anonymous. Attentional LSTM-Ensemble Architecture for Intrusion Detection in Smart Grids[J]. Scientific Reports, 2025.
- [12] INJADAT M, MOUBAYED A, NASSIF A B, et al. Multi-Stage Optimized Machine Learning Framework for Network Intrusion Detection[J]. IEEE Access, 2023, 11: 26338-26355.

- [13] NASSIF A B, TALIB M A, NASIR Q, et al. Machine learning for anomaly detection: A systematic review[J]. Ieee Access, 2021, 9: 78658-78700.
- [14] MEGANTARA A A, AHMAD T. A hybrid machine learning method for increasing the performance of network intrusion detection systems[J]. Journal of Big Data, 2021, 8(1): 142.
- [15] HASSAN M M, ISLAM M S, RAHMAN M A. Unsupervised Machine Learning for Anomaly Detection: A Systematic Review[J]. ACM Computing Surveys, 2023.
- [16] KIM S, PARK M, KIM H. Deep Learning-Based Network Intrusion Detection: A Survey [J]. IEEE Access, 2020, 8: 21954-21973.
- [17] DEVAN P, KHARE N. An efficient XGBoost–DNN-based classification model for network intrusion detection system[J]. Neural Computing and Applications, 2020, 32(16): 12499-12514.
- [18] GHORBANI A, FAKHRAHMAD S M. A deep learning approach to network intrusion detection using a proposed supervised sparse auto-encoder and svm[J]. Iranian Journal of Science and Technology, Transactions of Electrical Engineering, 2022, 46(3): 829-846.
- [19] DEMMESSE F A, NEUPANE A, KHORSANDROO S, et al. Machine Learning Based Fileless Malware Traffic Classification Using Image Visualization[J/OL]. Cybersecurity, 2023, 6. DOI: 10.1186/s42400-023-00170-z.
- [20] KHAN M A. HCRNNIDS: Hybrid convolutional recurrent neural network-based network intrusion detection system[J]. Processes, 2021, 9(5): 834.
- [21] WU P, GUO H, MOUSTAFA N. Pelican: A deep residual network for network intrusion detection[C]//2020 50th annual IEEE/IFIP international conference on dependable systems and networks workshops (DSN-W). 2020: 55-62.
- [22] SINHA J, MANOLLAS M. Efficient deep CNN-BiLSTM model for network intrusion detection[C]//Proceedings of the 2020 3rd International Conference on Artificial Intelligence and Pattern Recognition. 2020: 223-231.
- [23] LAN J, LIU X, LI B, et al. MEMBER: A multi-task learning model with hybrid deep features for network intrusion detection[J]. Computers & Security, 2022, 123: 102919.
- [24] FU Y, DU Y, CAO Z, et al. A deep learning model for network intrusion detection with imbalanced data[J]. Electronics, 2022, 11(6): 898.
- [25] 张安琳, 张启坤, 黄道颖, 等. 基于 CNN 与 BiGRU 融合神经网络的入侵检测模型. [J]. Journal of Zhengzhou University: Engineering Science, 2022, 43(3).

- [26] 杨月麟, 毕宗泽. 基于深度学习的网络流量异常检测[J]. 计算机科学, 2021, 48(S2): 540-546.
- [27] HOZOURI A, MIRZAEI A, EFFATPARVAR M. A comprehensive survey on intrusion detection systems with advances in machine learning, deep learning and emerging cybersecurity challenges[J]. Discover Artificial Intelligence, 2025, 5(1): 314.
- [28] XU C, LI D, LIU Z, et al. Few-shot network intrusion detection method based on multi-domain fusion and cross-attention[J]. PloS one, 2025, 20(7): e0327161.
- [29] ALITBI Z K, HOSSEINI SENO S A, GHAEMI BAFGHI A, et al. A Generalized and Real-Time Network Intrusion Detection System Through Incremental Feature Encoding and Similarity Embedding Learning[J]. Sensors, 2025, 25(16): 4961.
- [30] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]//International conference on machine learning. 2020: 1597-1607.
- [31] LECUN Y, BENGIO Y, HINTON G. Deep learning[J]. nature, 2015, 521(7553): 436-444.
- [32] FANG W, CHEN Y, XUE Q. Survey on research of RNN-based spatio-temporal sequence prediction algorithms[J]. Journal on Big Data, 2021, 3(3): 97.
- [33] XU X, LYU L. A reputation mechanism is all you need: Collaborative fairness and adversarial robustness in federated learning[Z]. 2020.
- [34] LEE S, HWANG S, KIM D. MADCluster: Model-agnostic Anomaly Detection with Self-supervised Clustering Network[J]. arXiv preprint arXiv:2505.16223, 2025.
- [35] PANG Y, PENG L, ZHANG H, et al. Imbalanced ensemble learning leveraging a novel data-level diversity metric[J]. Pattern Recognition, 2025, 157: 110886.
- [36] SHI Y, WANG B, YU Y, et al. Robust anomaly detection for multivariate time series through temporal GCNs and attention-based VAE[J]. Knowledge-Based Systems, 2023, 275: 110725.
- [37] AUDIBERT J, MICHIARDI P, GUYARD F, et al. Usad: Unsupervised anomaly detection on multivariate time series[C]//Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining. 2020: 3395-3404.
- [38] DENG A, HOOI B. Graph neural network-based anomaly detection in multivariate time series[C]//Proceedings of the AAAI conference on artificial intelligence: vol. 35: 5. 2021: 4027-4035.

- [39] XU J, WU H, WANG J, et al. Anomaly transformer: Time series anomaly detection with association discrepancy[J]. arXiv preprint arXiv:2110.02642, 2021.
- [40] RUFF L, VANDERMEULEN R A, GÖRNITZ N, et al. Deep One-Class Classification [J]. 2018.
- [41] LI Y, LYU X, KOREN N. Neural attention distillation: Erasing backdoor triggers from deep neural network[C]//International Conference on Learning Representations. 2021: 1-19.
- [42] TIANYU G, BRENDAN D G, SIDDHARTH G. Badnets: Identifying vulnerabilities in the machine learning model supply chain[J]. IEEE Access, 2019, 7: 47230-47244.
- [43] YINGQI L, SHIQING M, YOUSRA A, et al. Trojaning attack on neural networks[C]//NDSS. 2018.
- [44] XINYUN C, CHANG L, BO L, et al. Targeted backdoor attacks on deep learning systems using data poisoning[Z]. 2017.
- [45] ALEXANDER T, DIMITRIS T, ALEKSANDER M. Clean-label backdoor attacks[Z]. 2019.
- [46] MAURO B, KASSEM K, BENEDETTA T. A new backdoor attack in cnns by training set corruption without label poisoning[C]//ICIP. 2019.
- [47] BARUCH G, BARUCH M, GOLDBERG Y. A little is enough: Circumventing defenses for distributed learning[C]//Neural Information Processing Systems. 2019: 8632-8642.
- [48] CHEN C, ZHANG J, TUNG A. Robust federated recommendation system[Z]. 2020.

## 攻读硕士学位期间发表的论文及科研成果

### 论文发表或出版情况

- [1] 以学生一作在 Gas Science and Engineering (中科院 2 区) 上发表论文 2 篇
- [2] 以四作在 Geoenergy Science and Engineering (中科院 2 区) 上发表论文 1 篇

### 专利授权和申请情况

- [1] 已获得国家授权专利 3 项

### 个人获奖及证书情况

- [1] 2022. ”中国光谷·华为杯”第十九届中国研究生数学建模竞赛三等奖（团队成员）
- [2] 2022. 研究生学业一等奖学金
- [3] 2023. ”华为杯”第二十届中国研究生数学建模竞赛二等奖（队长）
- [4] 2023. 第十一届”泰迪杯”数据挖掘挑战赛全国研究生组三等奖（队长）
- [5] 2023. ”建行杯”四川省国际大学生创新大赛银奖（团队成员）
- [6] 2023. 第三届四川省大学生数据挖掘挑战赛研究生组三等奖（团队成员）
- [7] 2024. ”华为杯”第二十一届中国研究生数学建模竞赛三等奖（团队成员）
- [8] 2024. 研究生国家奖学金
- [9] 2024. 西南石油大学优秀研究生
- [10] 2024. 西南石油大学优秀毕业生